



Global
AI Hub

10million.AI

Görüntü İşlemeye Giriş

Diclehan ve Oğuzhan Ulucan
Aralık 2024

İçerik

1. Görüntü İşleme Tanımı ve Kapsamı
2. Temel Görüntü İşleme Tekniklerinden Örnekler
3. Konvolüsyonel Sinir Ağları (CNNs)
4. Renk Sabitliği

Görüntü İşleme Tanımı ve Kapsamı

Kullanım Alanları

Sağlık: Tıbbi görüntü analizi (MR, BT, röntgen), kanser teşhisleri, retina taraması, gıda kalitesi kontrolü

Güvenlik: Yüz tanıma, plaka tanıma, video gözetim analizi, obje takibi ve sınıflandırması, doğal afet sonrası değerlendirme

Otomotiv: Otonom araçlarda nesne algılama, yol şeridi takibi, engel tespiti

E-ticaret: Fotoğraf ile ürün bulma, ürün önerileri, augmented reality ile ürün deneme

Tarım/Gıda: Bitki sağlığı tespiti, bozuk gıda tespiti, drone görüntülerinden veri çıkarma

Sanayi: Üretim hattında kalite kontrol, hata algılama

Computational Photography: Görüntü düzenleme (İyileştirme?)

Diğer: Filtreleme (Instagram, Photoshop), oyun teknolojileri

Görüntü İşleme Tanımı ve Kapsamı

Yapay Zeka Uygulamalarındaki Yeri

Bilgisayarla Görü (Computer Vision):

- Yapay zeka, görüntü işleme ile birleşir
- Görüntü işleme, veriyi hazırlar ve bilgisayarla görme algoritmalarına girdi sağlar

Derin Öğrenme (Deep Learning):

- CNN gibi yapılar, görüntü işleme için devrim yaratmıştır
 - Nesne algılama (Object Detection)
 - Segmentasyon (Segmentation)
 - Görüntü sınıflandırma (Image Classification)



Görüntü İşleme Tanımı ve Kapsamı

Yapay Zeka Uygulamalarındaki Yeri

Gerçek Zamanlı Uygulamalar:

- Otonom araçlarda anlık nesne algılama
- Spor analizinde oyuncu hareketlerinin gerçek zamanlı tespiti
- Akıllı kameralar ile tehlike/nesne tespiti, evcil hayvan takibi

Doğal Dil İşleme ve Görüntü İşleme Birleşimi:

- Görüntü açıklaması oluşturma (Image Captioning): Bir fotoğrafı betimleyen metinlerin oluşturulması
- Görüntüye dayalı soru-cevap sistemleri: Bir fotoğraftaki nesne hakkında soru sorma



Resimde neler var?

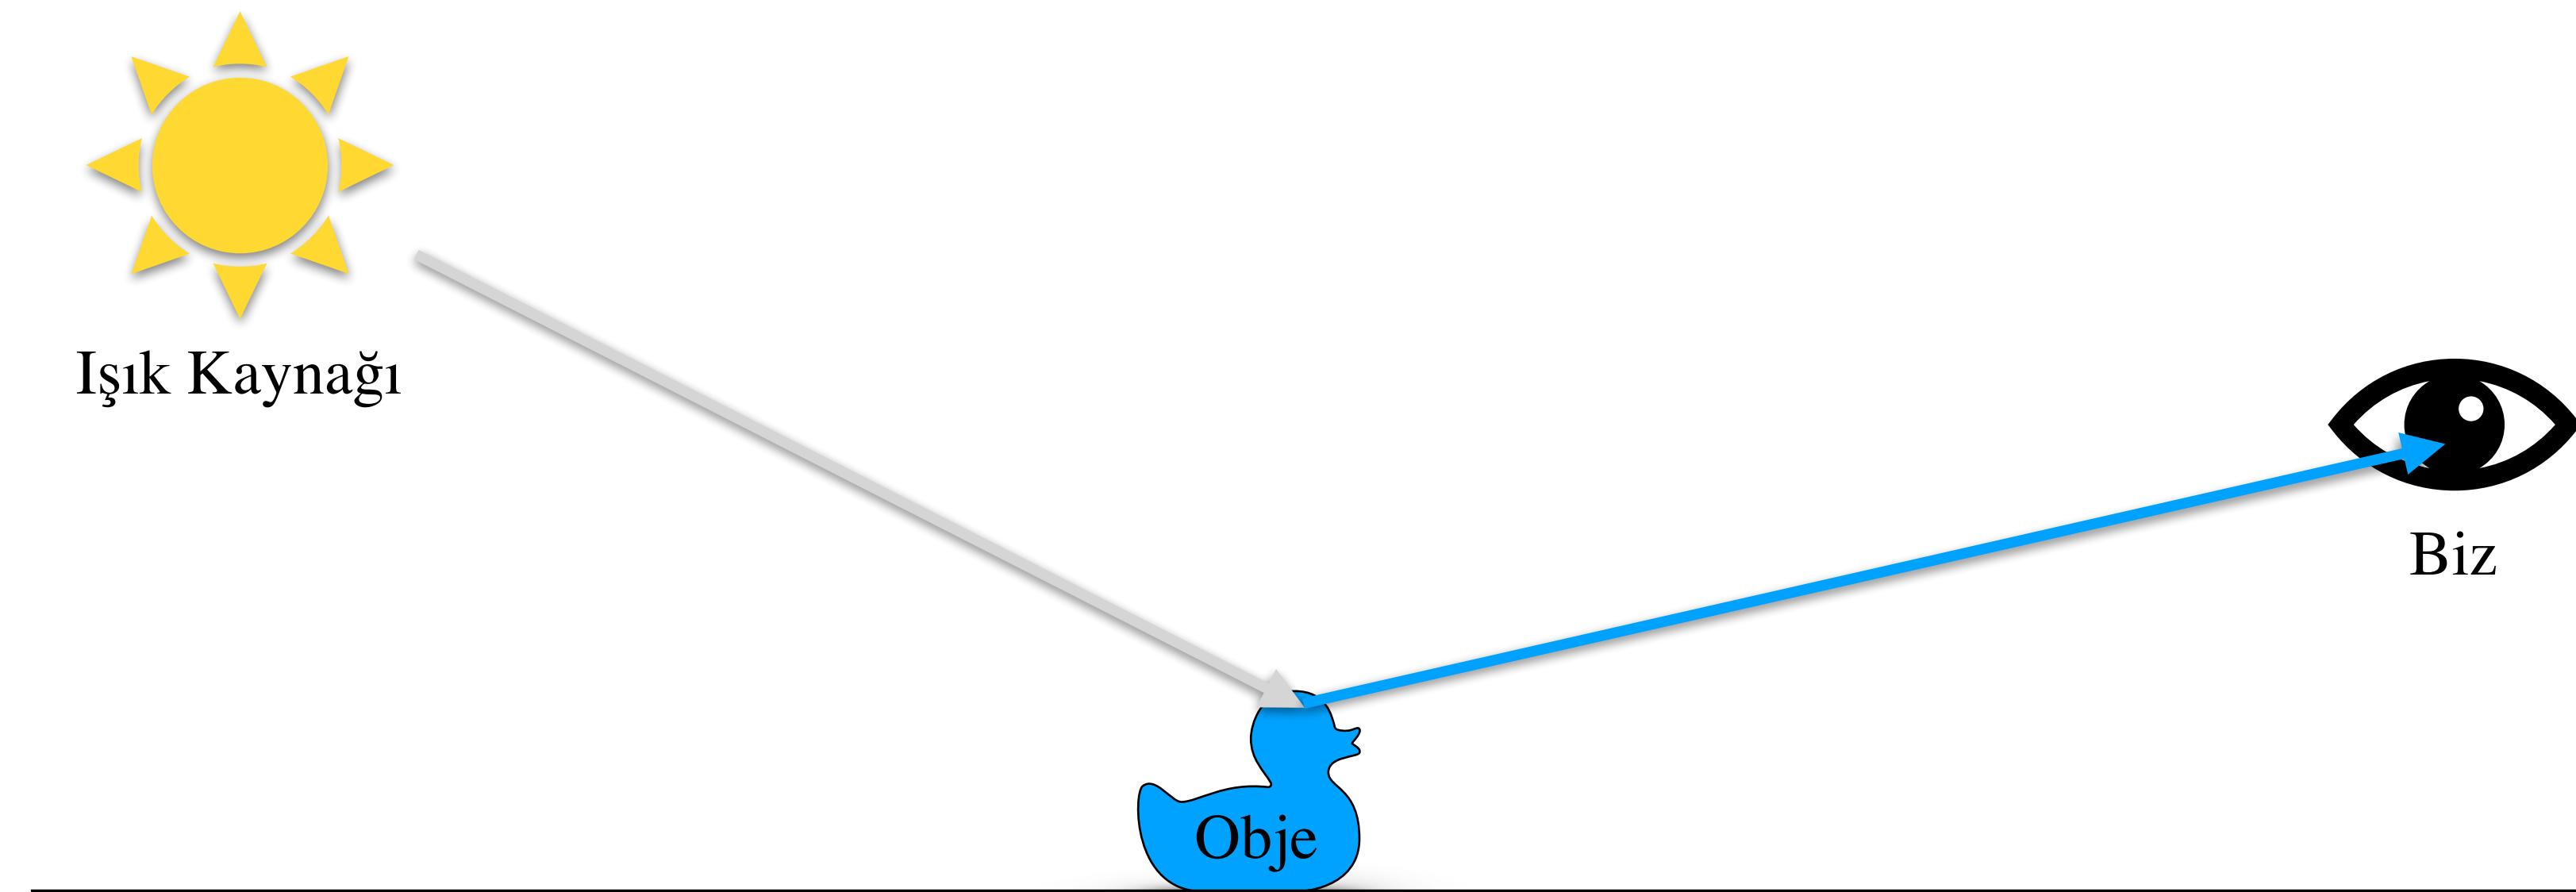
- Bir köpek, tren rayları ve bitkiler

Görüntü İşleme Tanımı ve Kapsamı

Nasıl Görürüz?

Işık/sinyal, sensör dizisine düşer ve sensörler gelen sinyali ölçer.

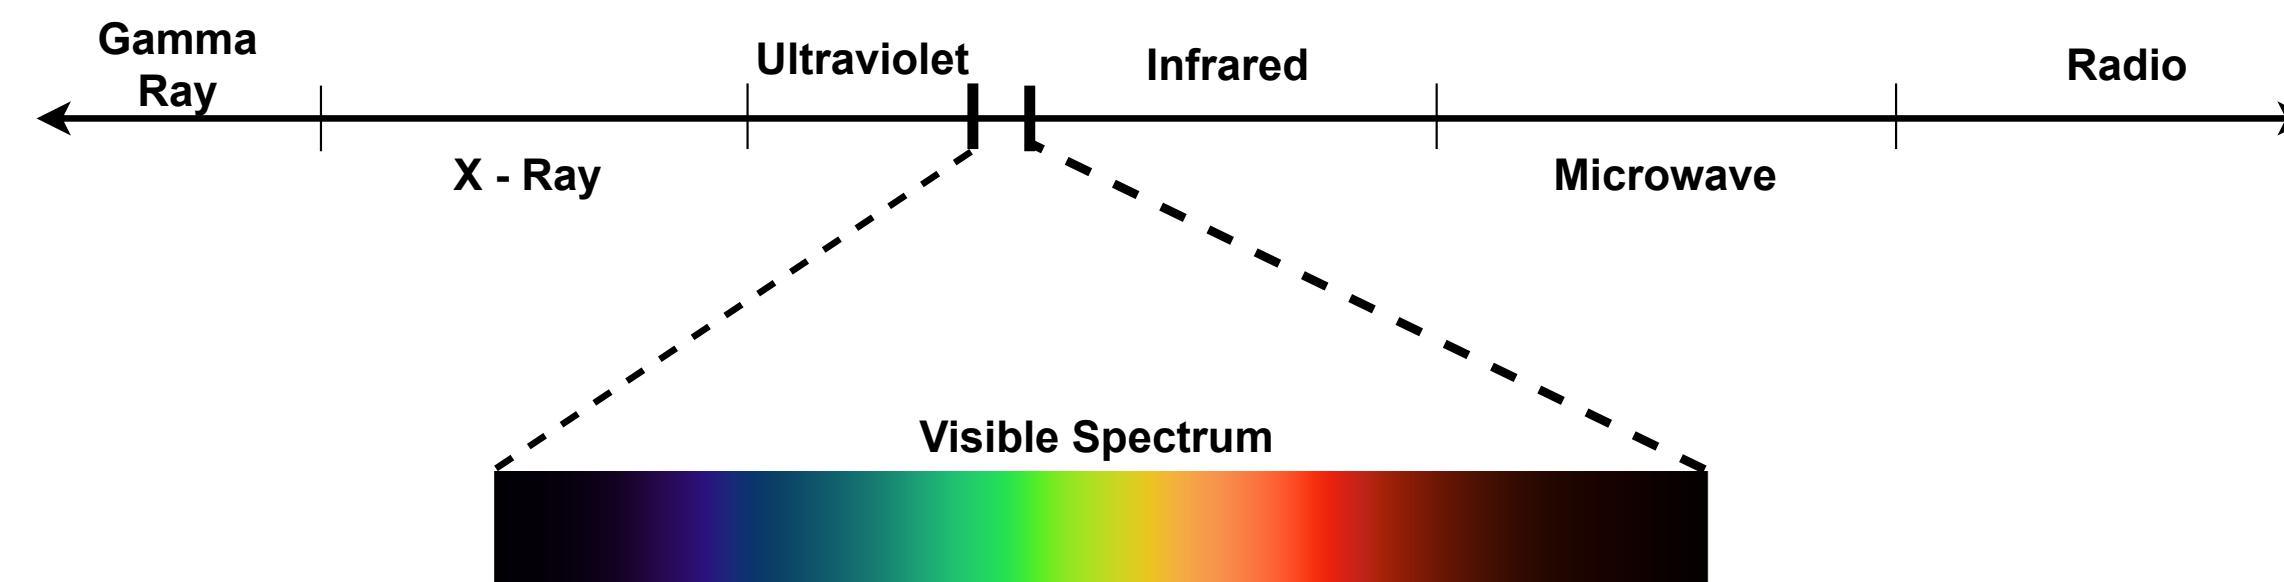
Sensörler, görünür spektrumun/dalga boyunun belirli bölümlerinden sorumludur.



Görüntü İşleme Tanımı ve Kapsamı

Nasıl Görürüz?

Biz, elektromanyetik spektrumun yalnızca dar bir bölgesine duyarlıyız.



Kırmızı gördüğünüzde, gözüneze **uzun** dalga boyuna sahip ışığın ulaştığını gösterir.

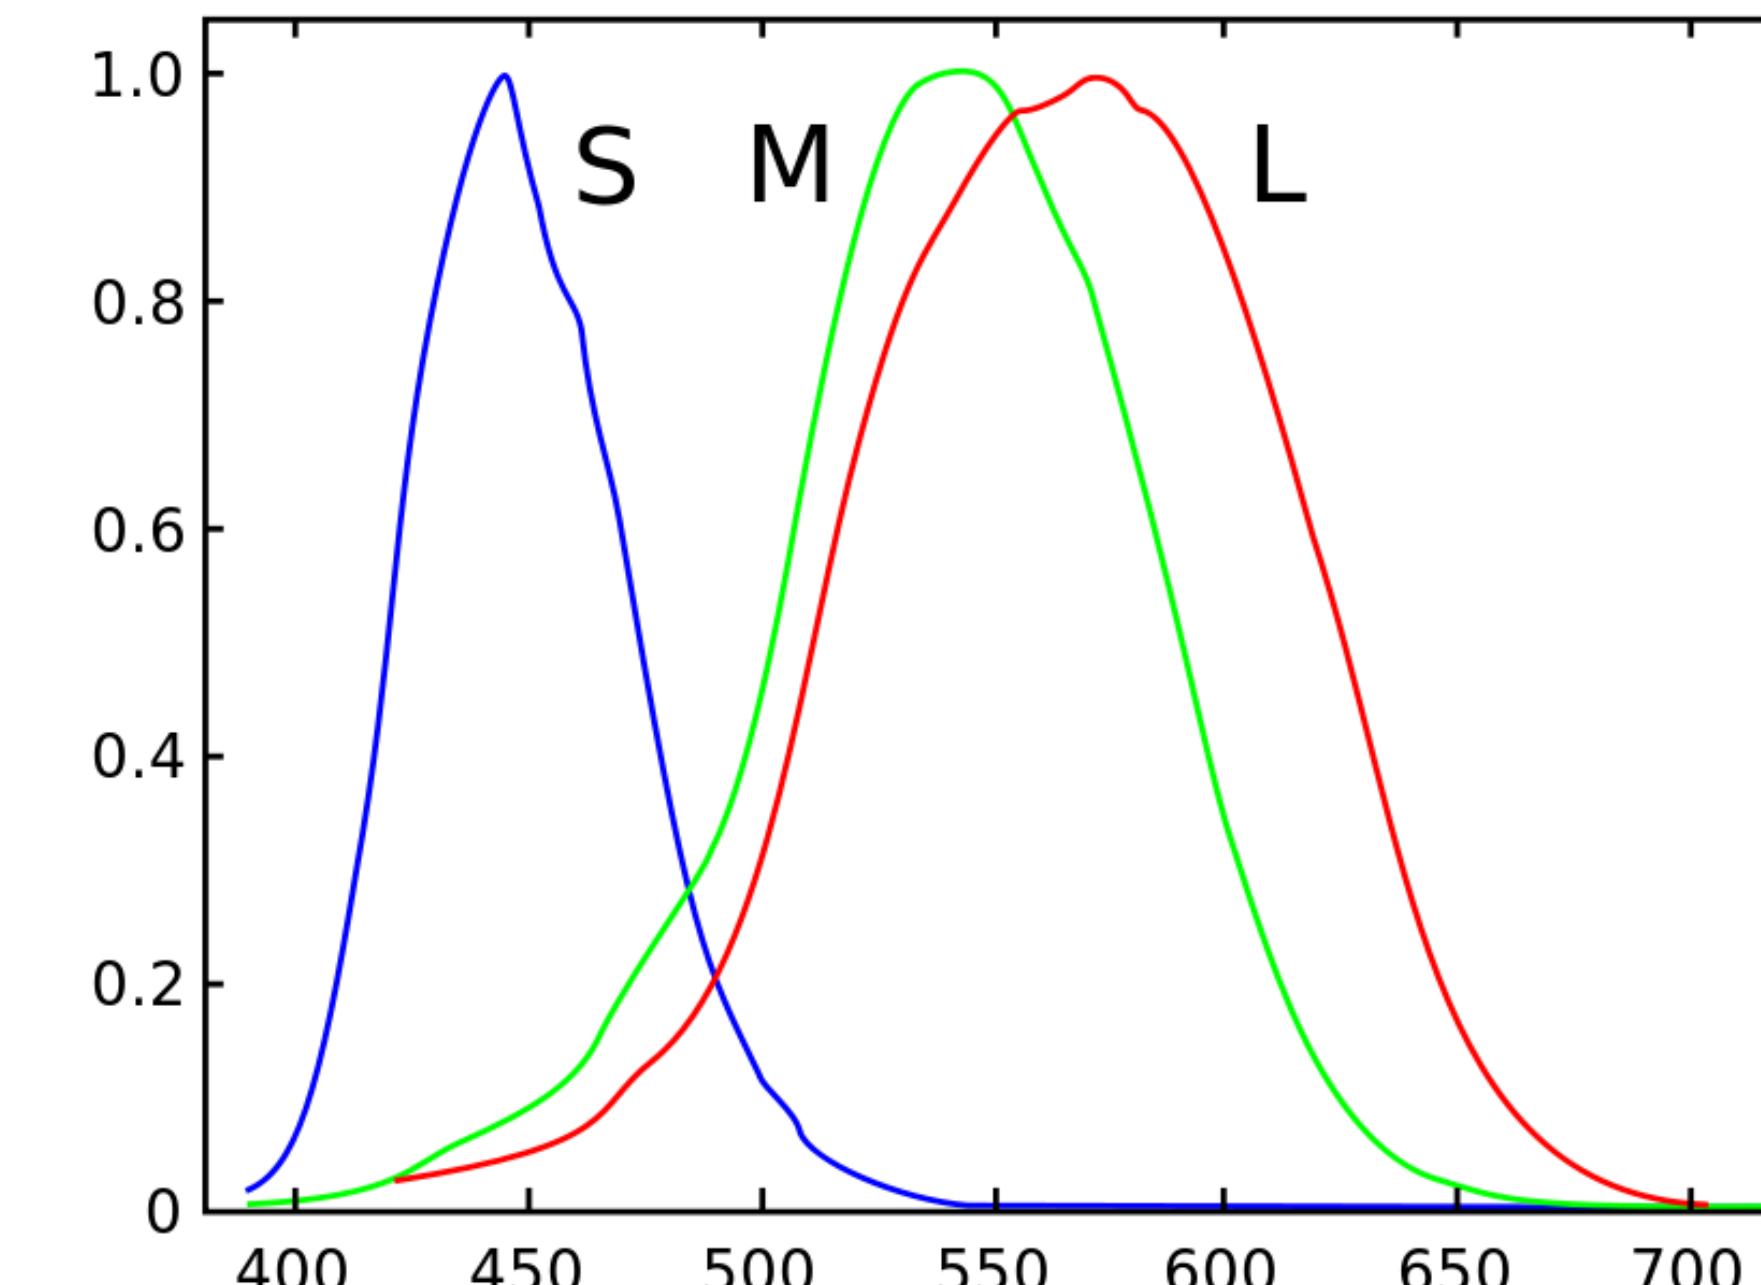
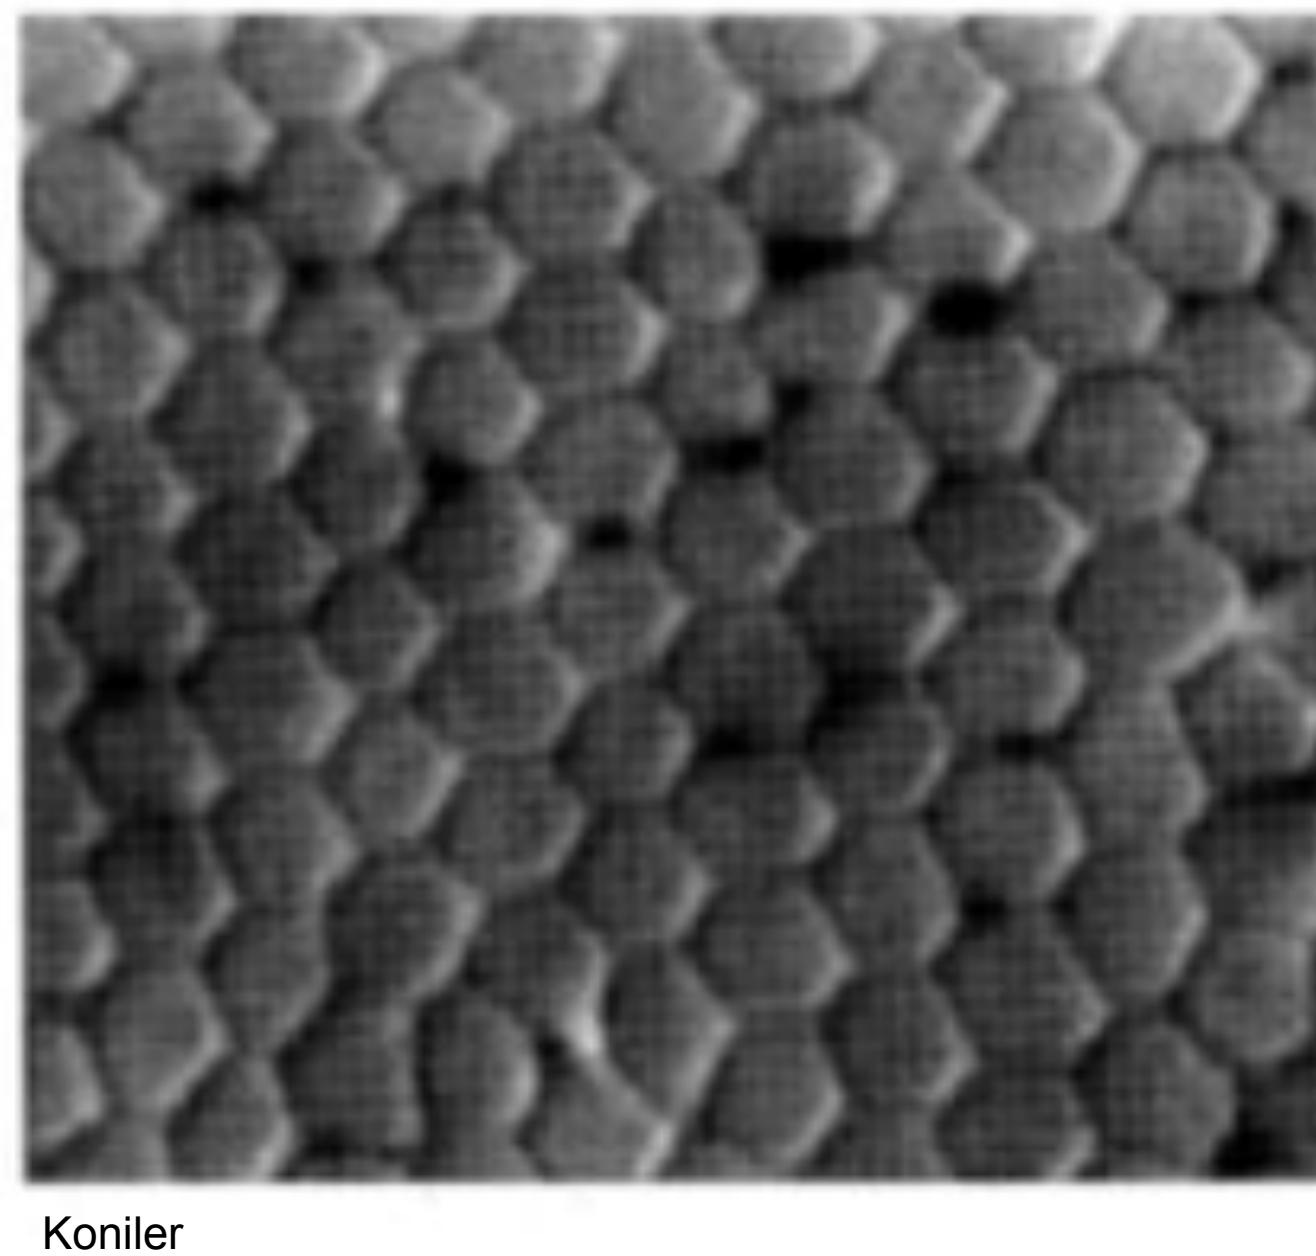
Yeşil gördüğünüzde, gözüneze **orta** dalga boyuna sahip ışığın ulaştığını gösterir.

Mavi gördüğünüzde, gözüneze **kısa** dalga boyuna sahip ışığın ulaştığını gösterir.

Görüntü İşleme Tanımı ve Kapsamı

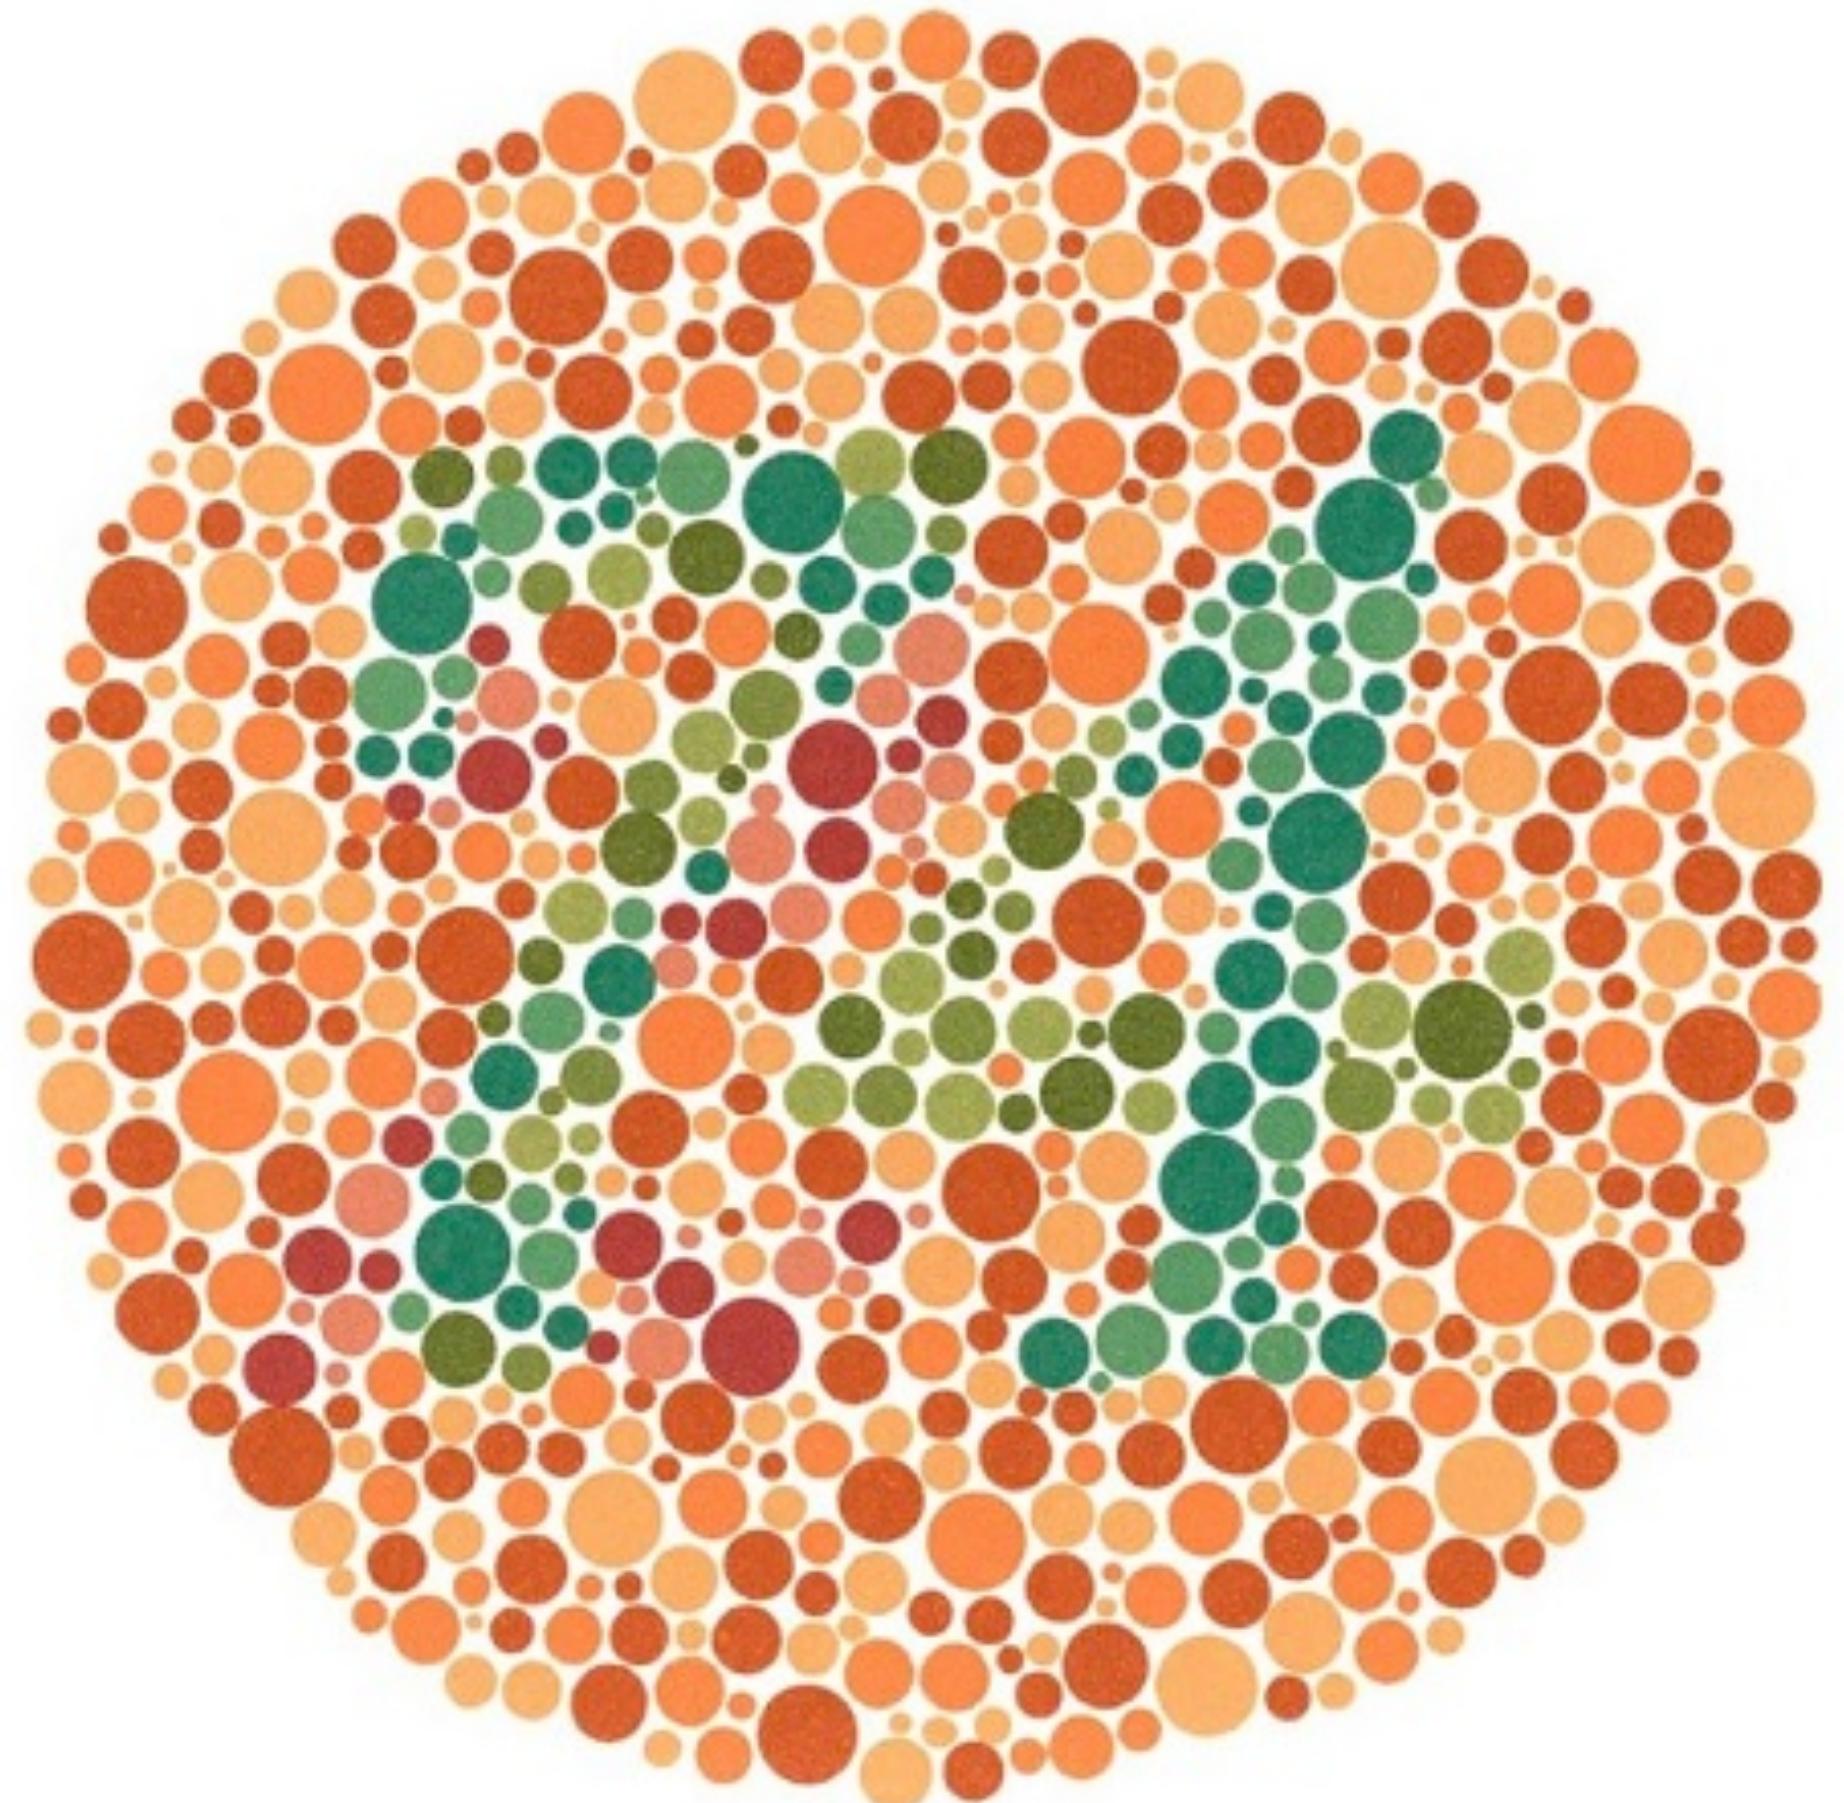
Nasıl Görürüz?

Biz, elektromanyetik spektrumun yalnızca dar bir bölgesine duyarlıyız.



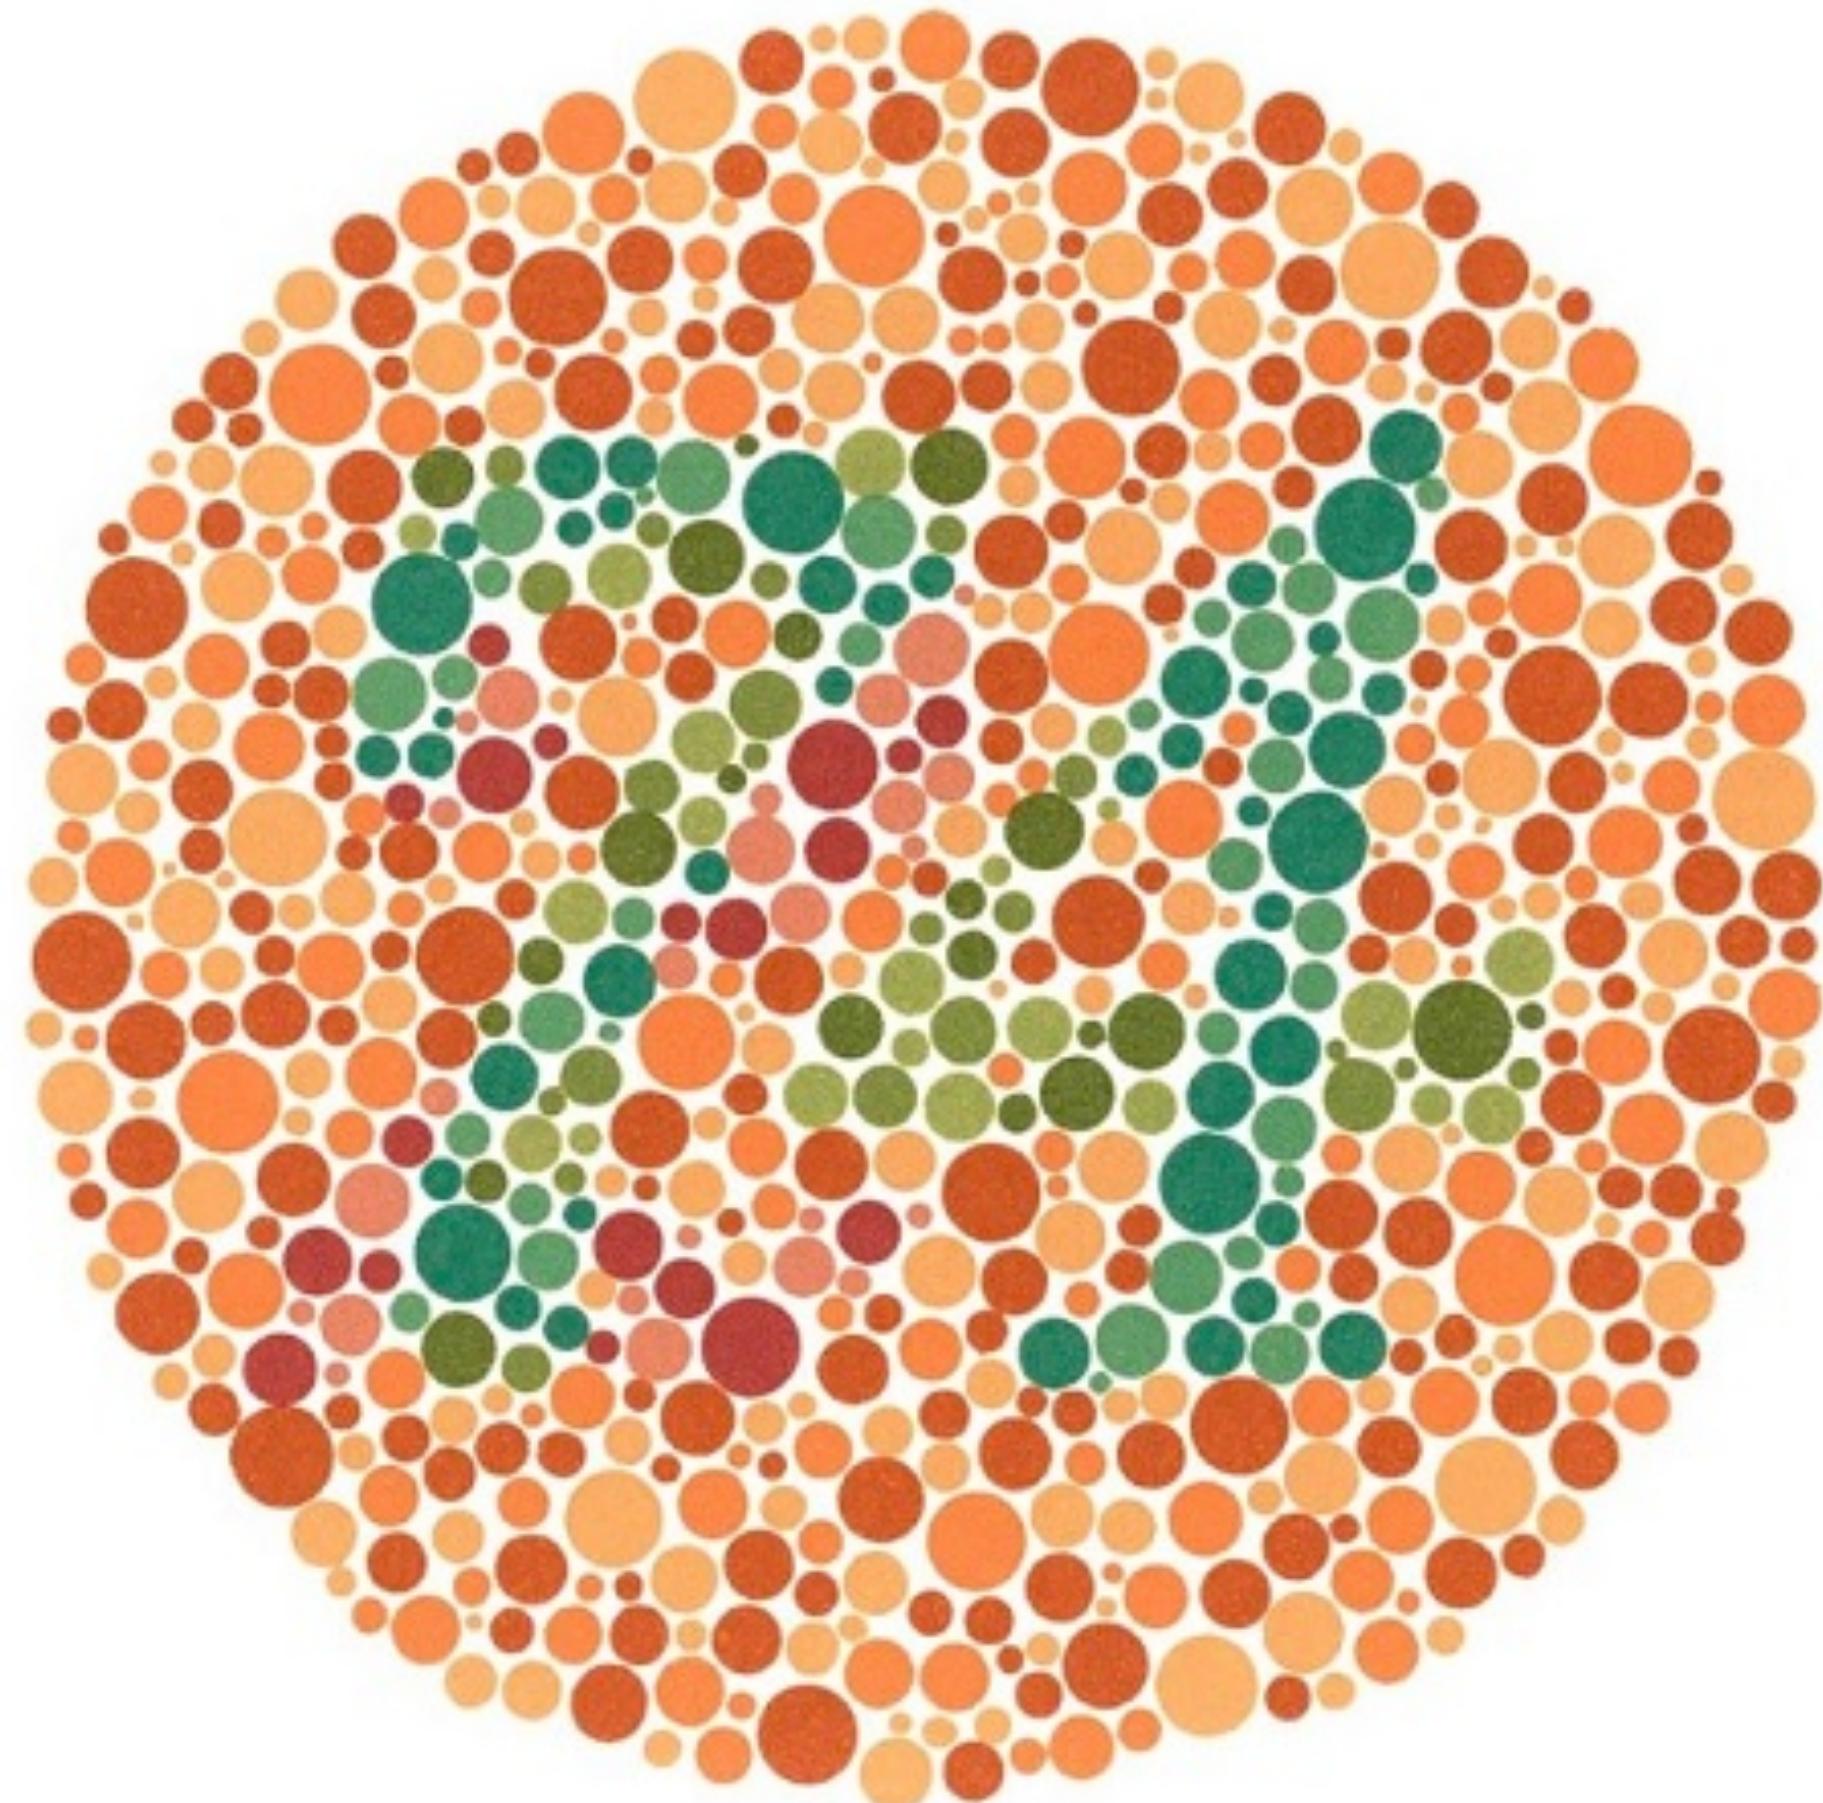
Görüntü İşleme Tanımı ve Kapsamı

Nasıl Görürüz?



Görüntü İşleme Tanımı ve Kapsamı

Nasıl Görürüz?



Normal Görüş / Renk körü

74 / 21

Görüntü İşleme Tanımı ve Kapsamı

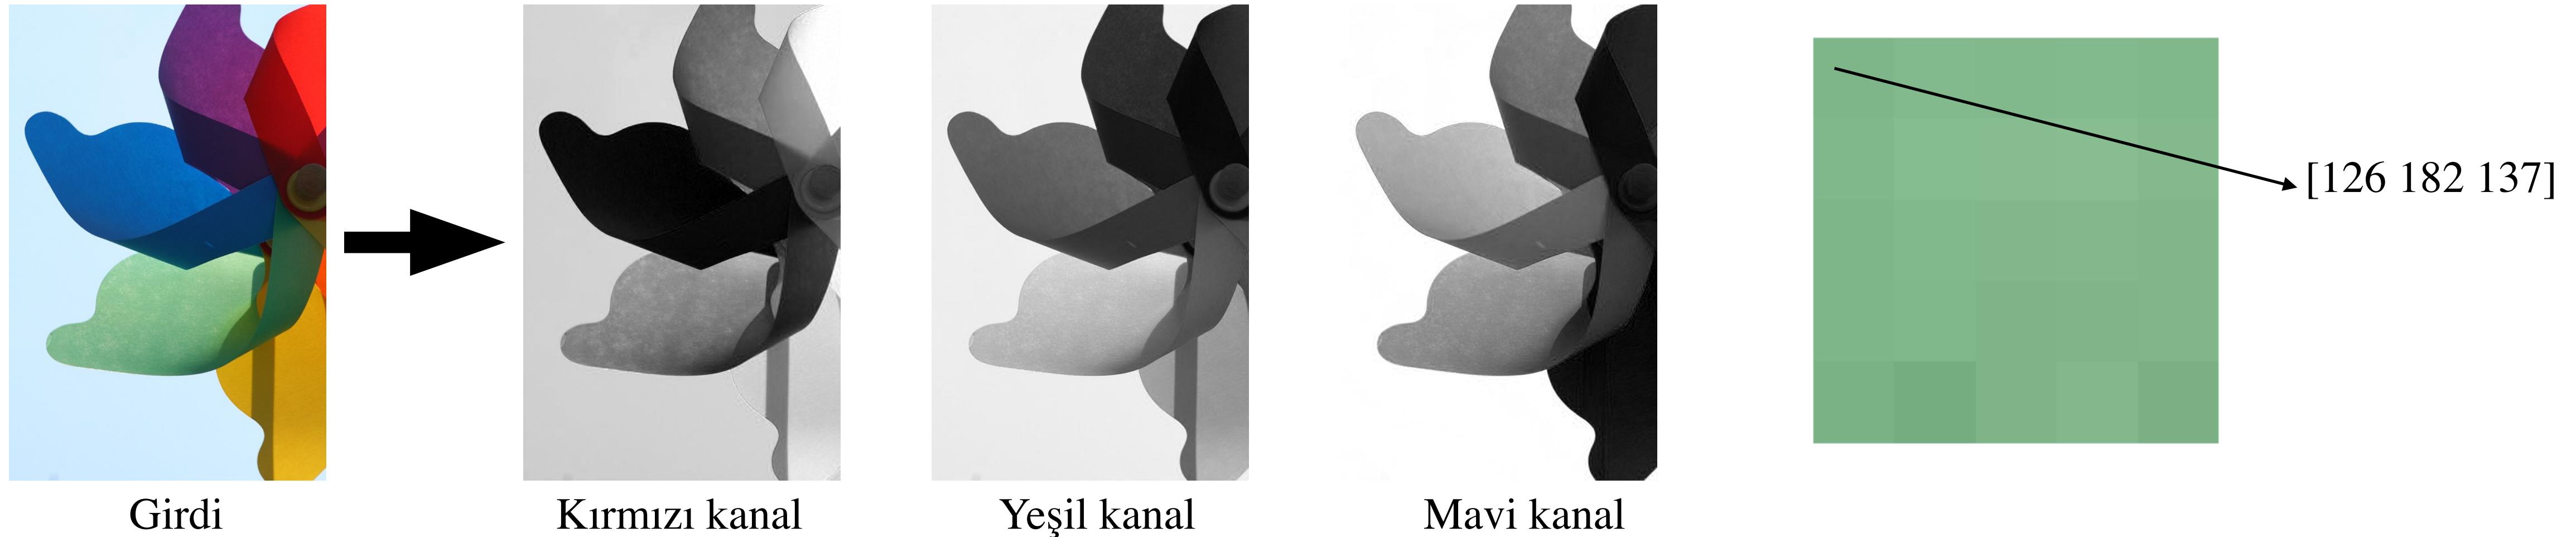
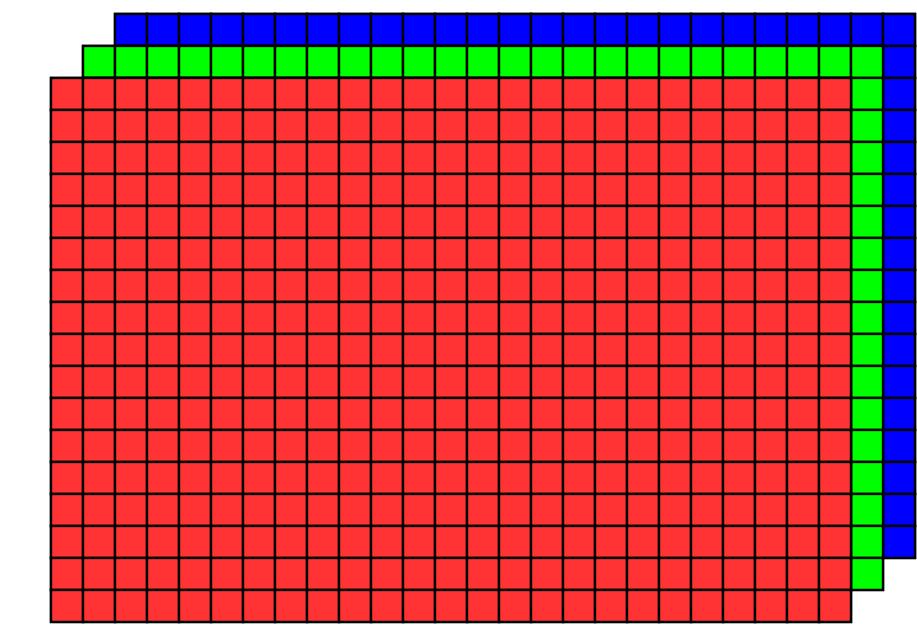
Dijital Görüntü İşleme Nasıl Gerçekleşir?

Genel olarak, görüntülerde 3 renk kanalı bulunur.

Her kanal, piksel adı verilen öğeleri içeren bir matrisi oluşturur.

Her pikselin 0 ile 255 arasında bir değeri vardır (8 bit görüntüler için).

$[0, 0, 0]$ = siyah $[255, 255, 255]$ = beyaz $[255, 0, 0]$ = kırmızı $[0, 255, 0]$ = yeşil $[0, 0, 255]$ = mavi



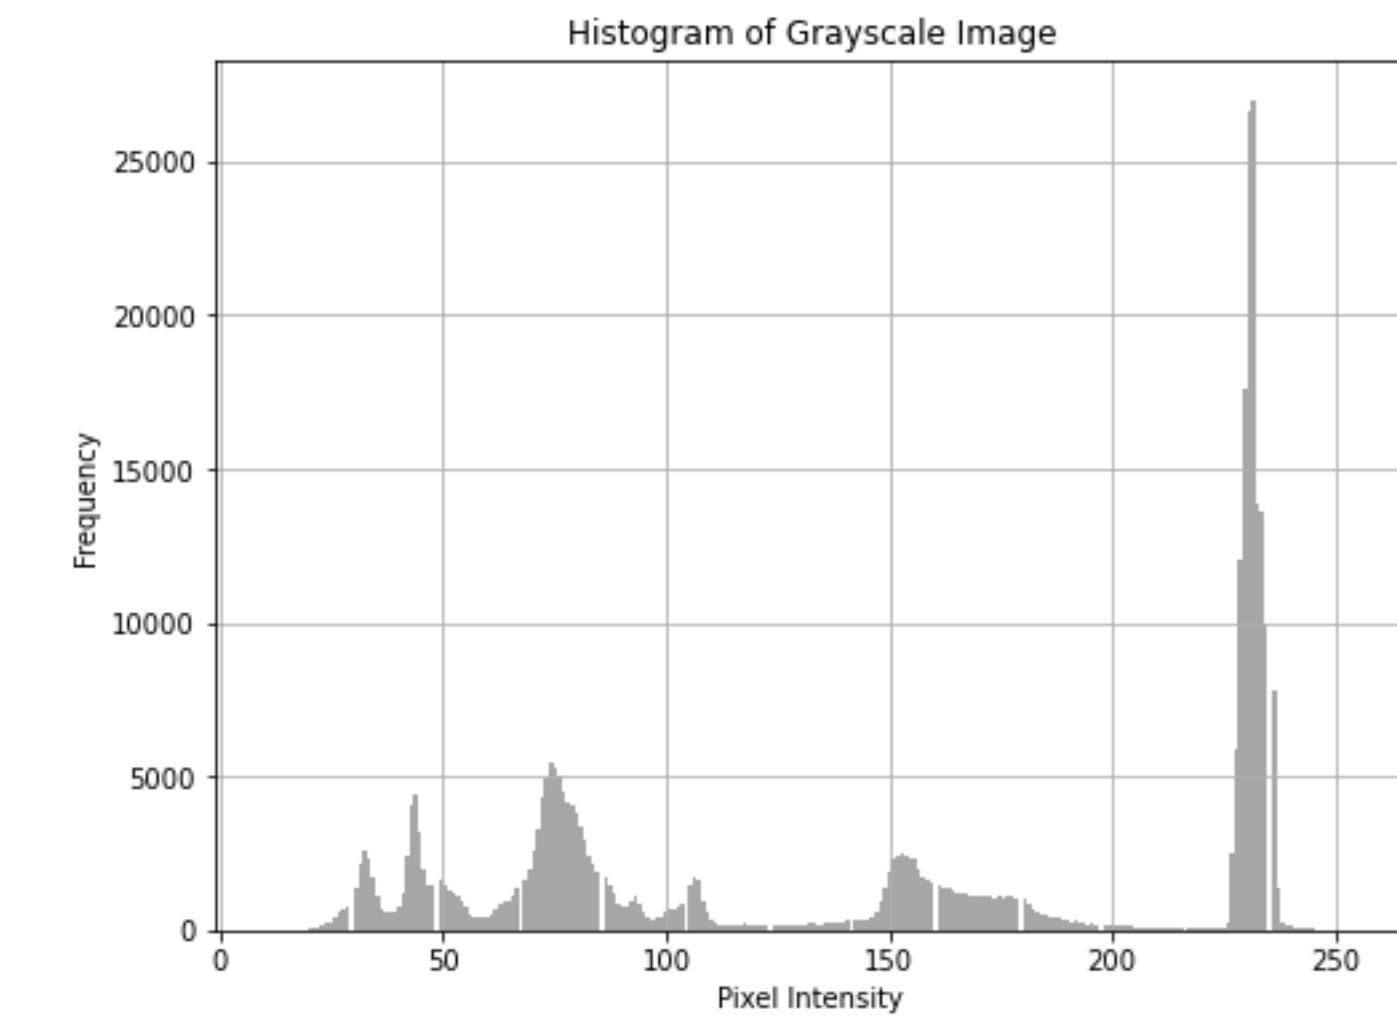
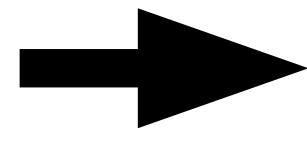
Temel Görüntü İşleme Teknikleri

Histogram

Bir görüntünün histogramı, görüntüdeki piksel yoğunlıklarının dağılımının grafiksel bir temsildir.

Görüntüde her yoğunluk değerine sahip kaç piksel bulunduğunu gösterir.

Histogram, bir görüntünün kontrasını, parlaklığını ve genel pozlamasını anlamaya yardımcı olur.

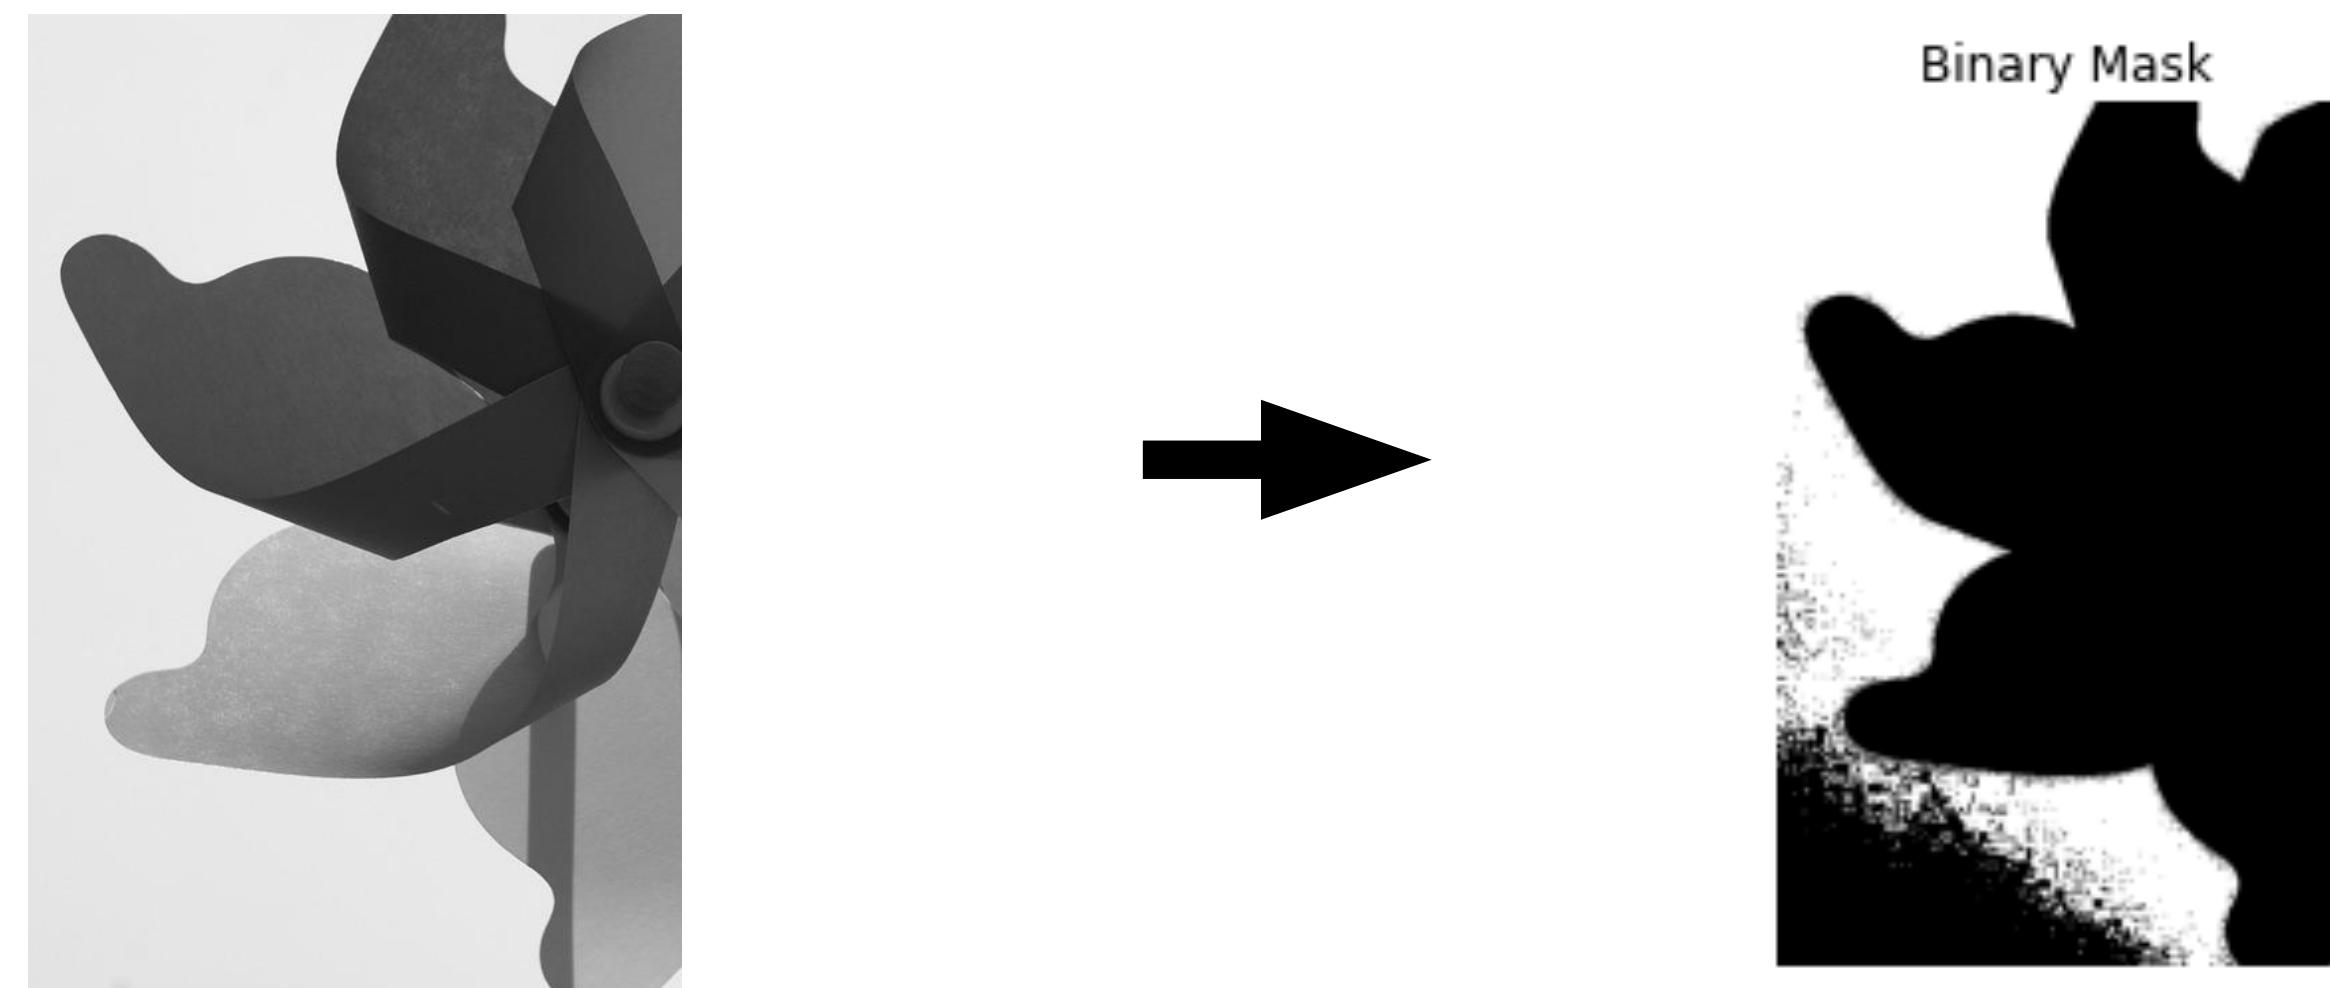


Temel Görüntü İşleme Teknikleri

Eşikleme (Thresholding)

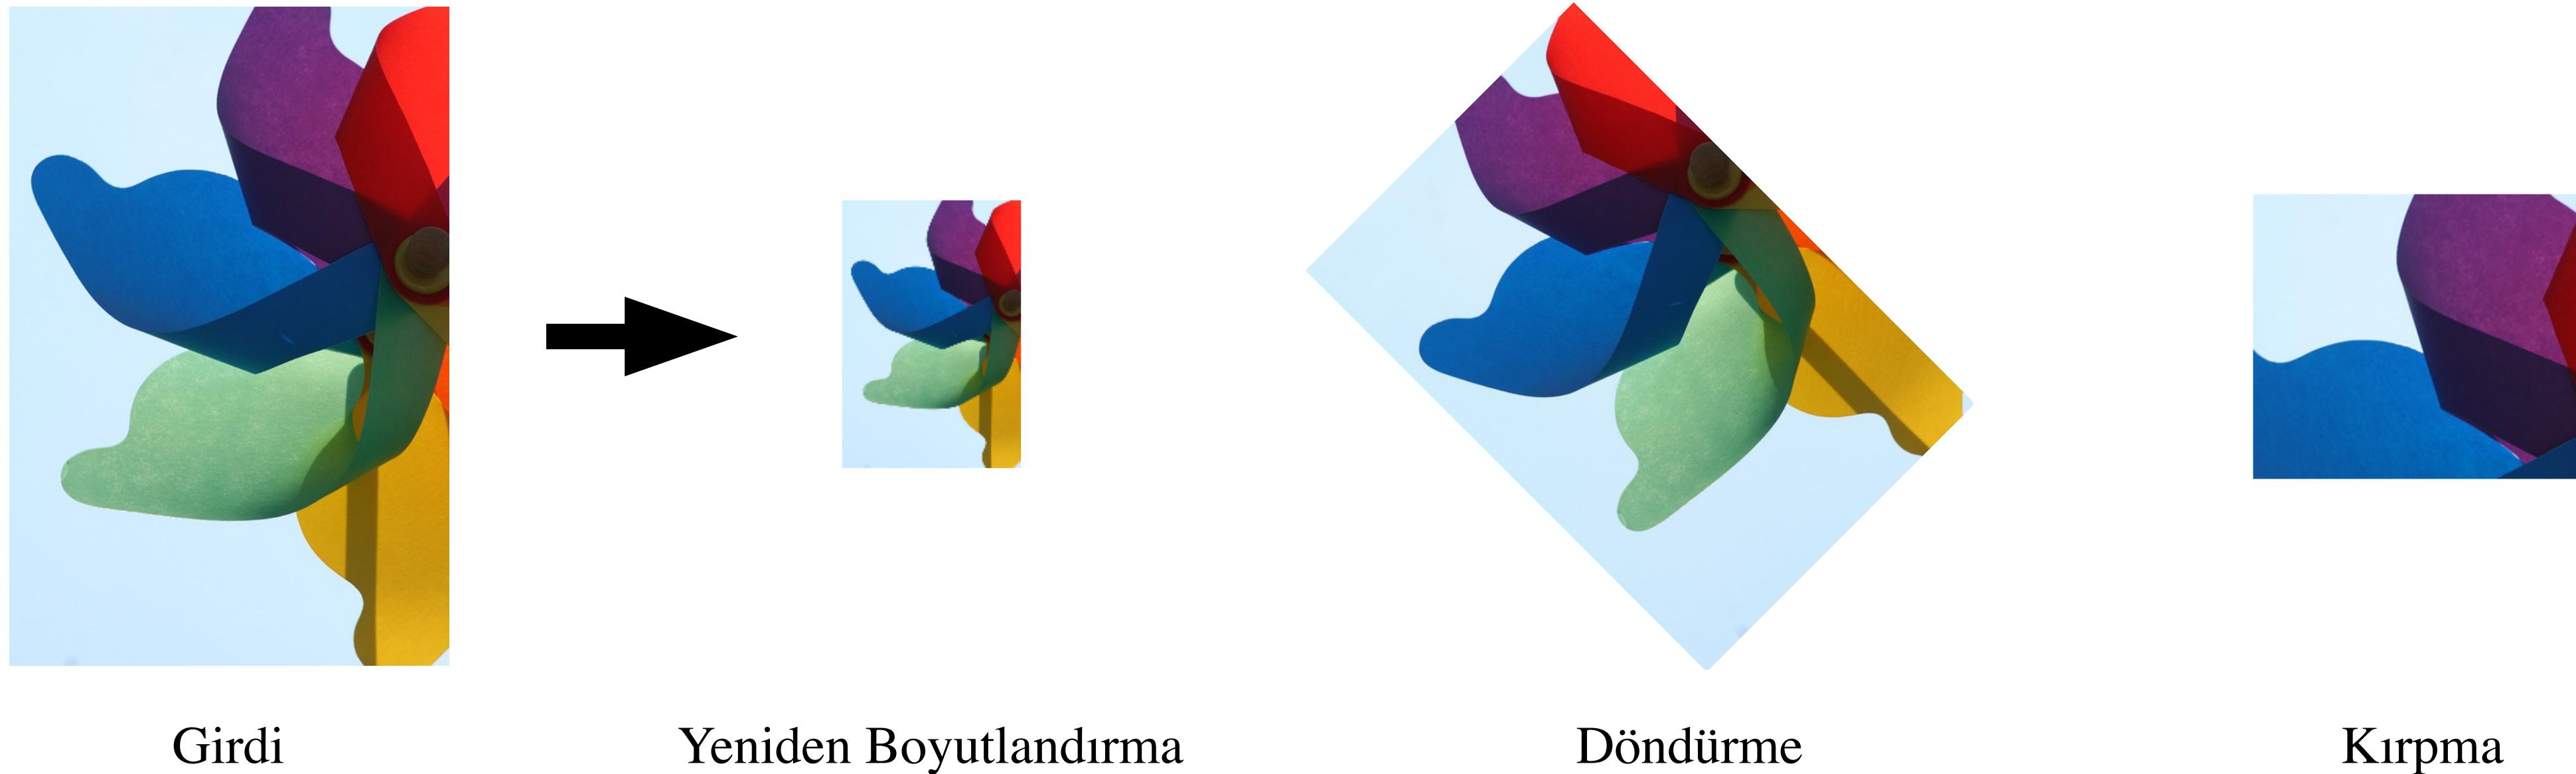
Eşikleme, gri tonlamalı bir görüntüden ikili (binary) bir görüntü oluşturmak için kullanılan basit bir görüntü işleme tekniğidir.

Bu teknik, nesneleri arka plandan ayırmak için kullanılabilir (örneğin, parlak nesneleri karanlık bir arka plandan ayırmak).



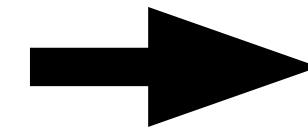
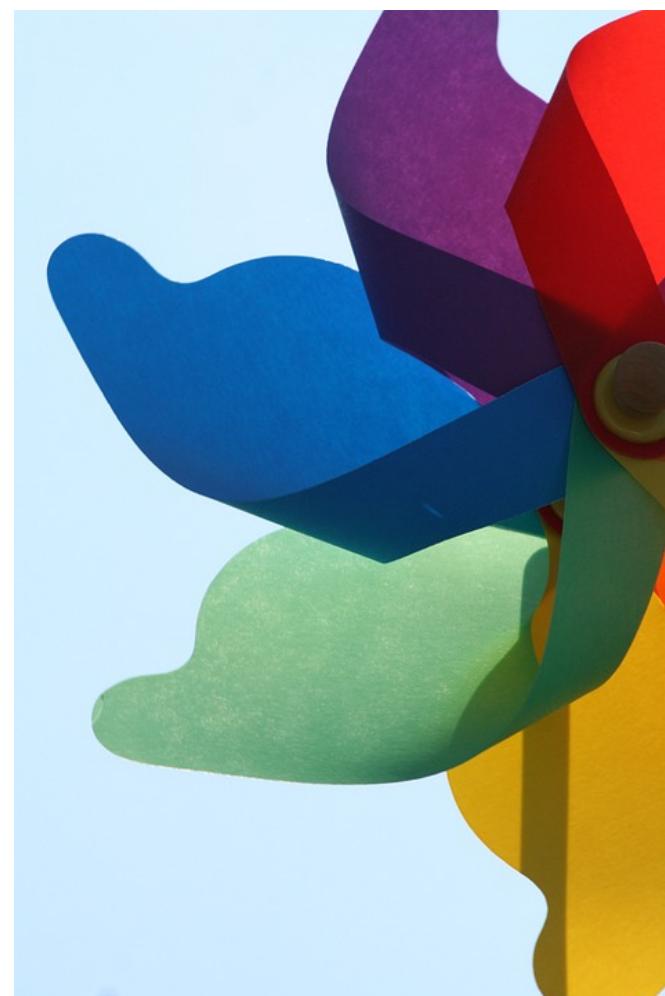
Temel Görüntü İşleme Teknikleri

Yeniden Boyutlandırma, Döndürme ve Kırpma

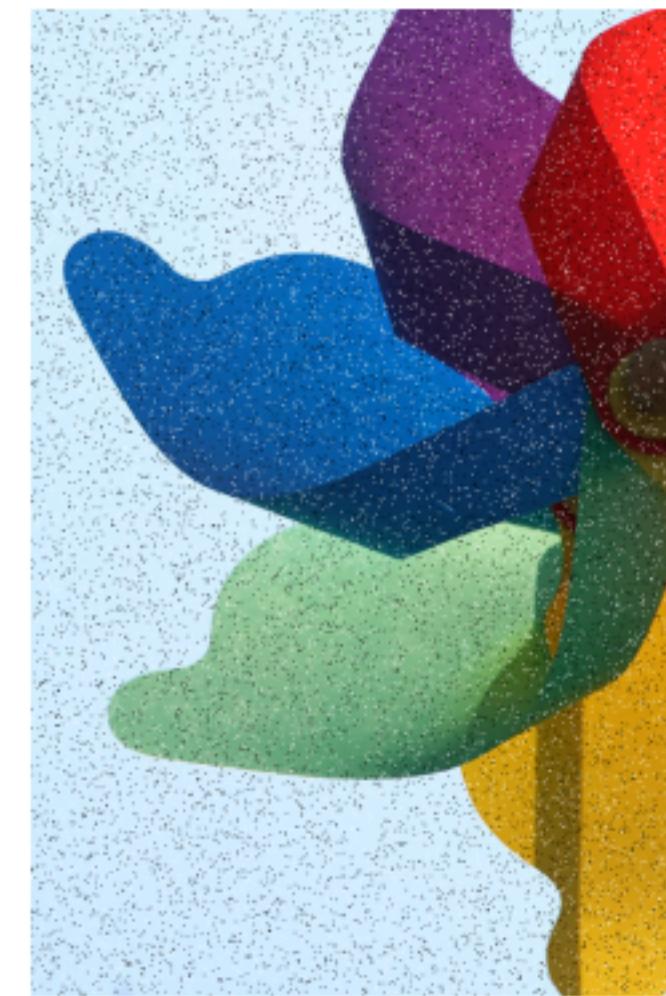


Temel Görüntü İşleme Teknikleri

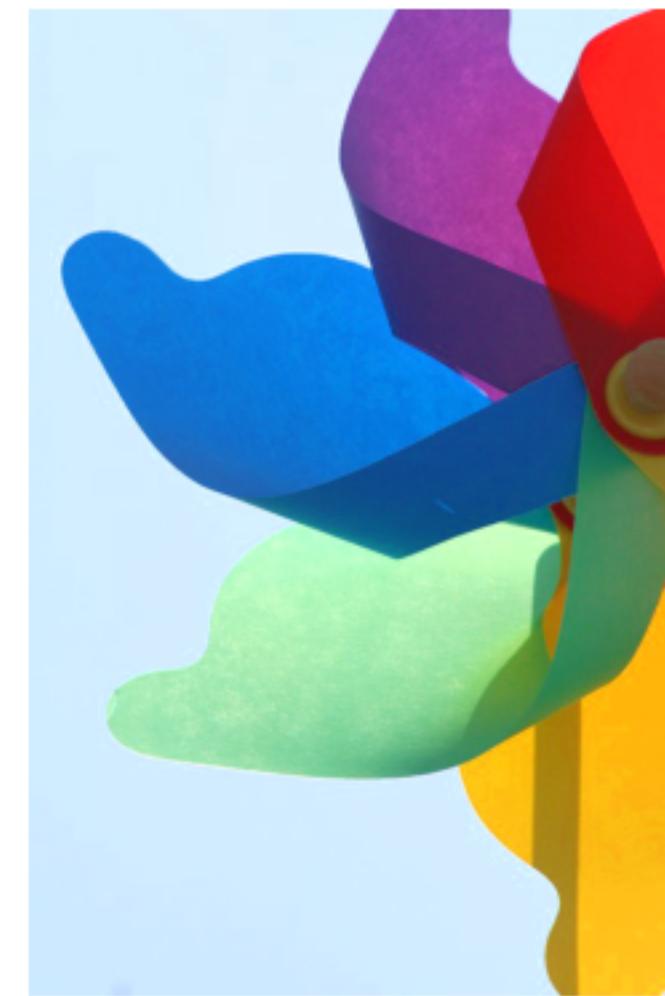
Gürültü Ekleme ve Parlaklık Değiştirme



Girdi



Gürültü Ekleme



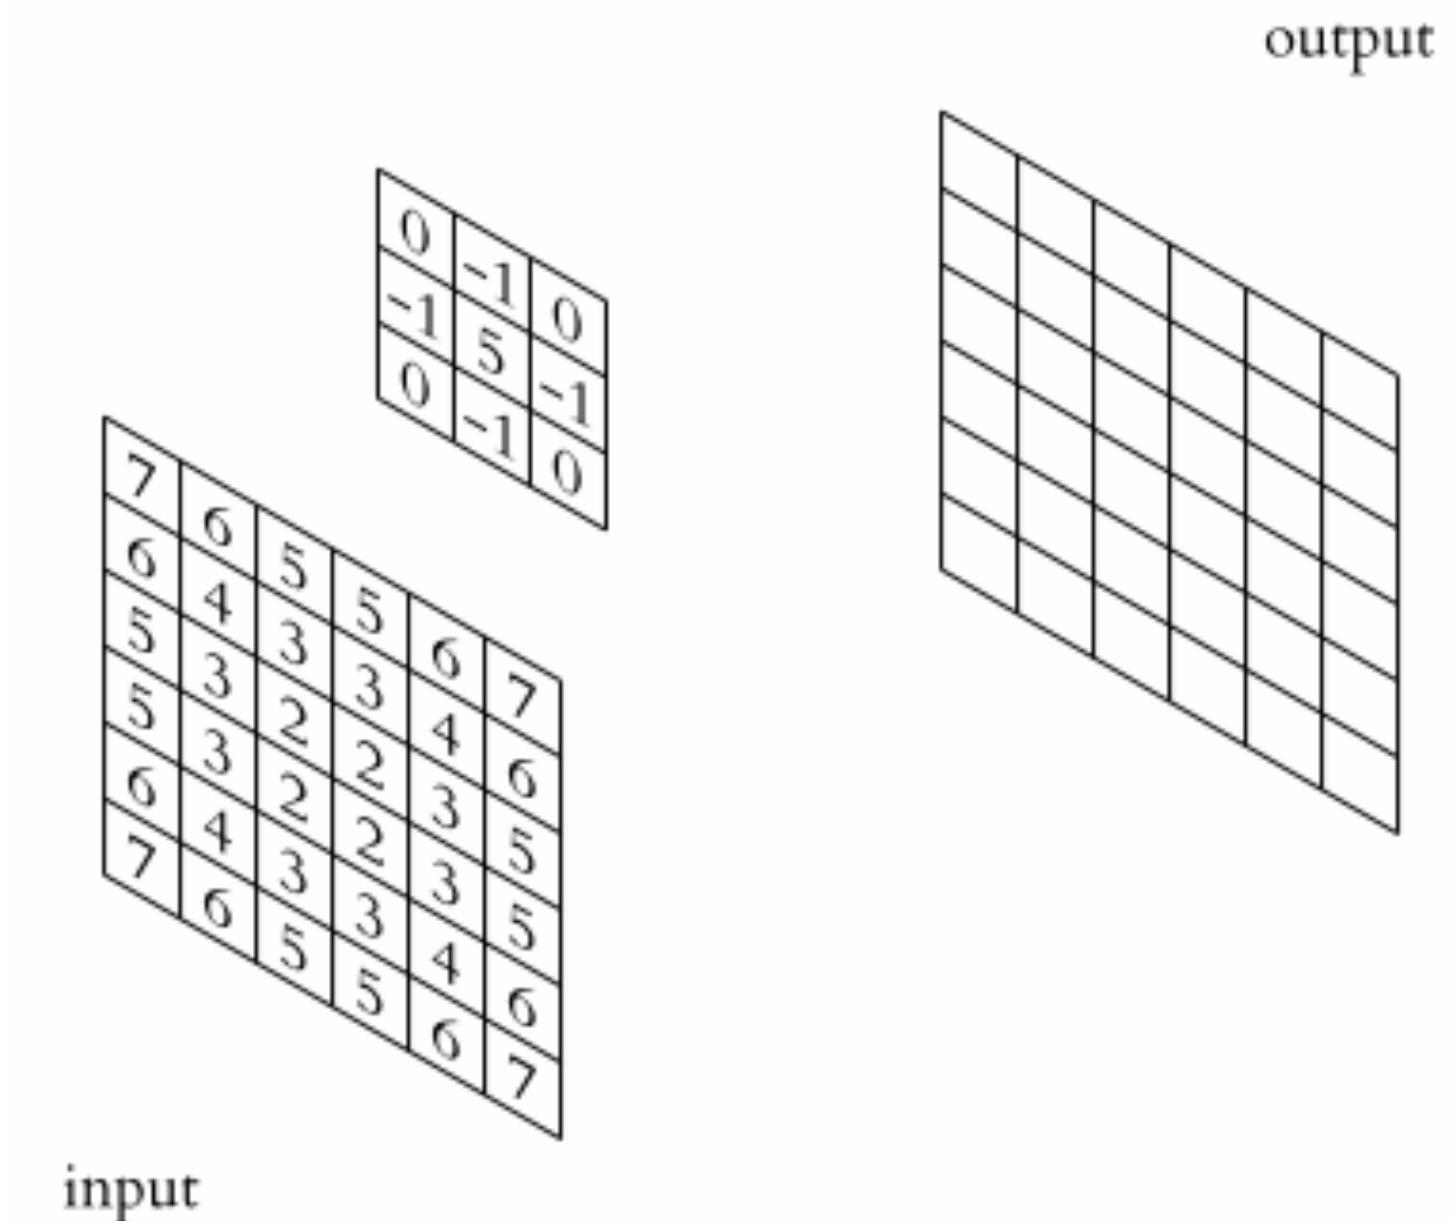
Parlaklık Değiştirme

Temel Görüntü İşleme Teknikleri

Konvolüsyon (Convolution)

Konvolüsyon, görüntü işlemede temel bir işlemidir çünkü bir görüntüye filtreler yani çekirdekler (kernel) uygulayarak onu faydalı şekillerde dönüştürmemize ve özellikleri çıkarmamıza olanak tanır.

- Kenar Tespiti (Edge Detection)
- Bulanıklaştırma ve Yumuşatma (Blurring and Smoothing)
- Keskinleştirme (Sharpening)
- Gürültüyü Azaltma (Reducing Noise)
- Kontrastı İyileştirme (Improving Contrast)
- Özellik Çıkarma (Feature Extraction)

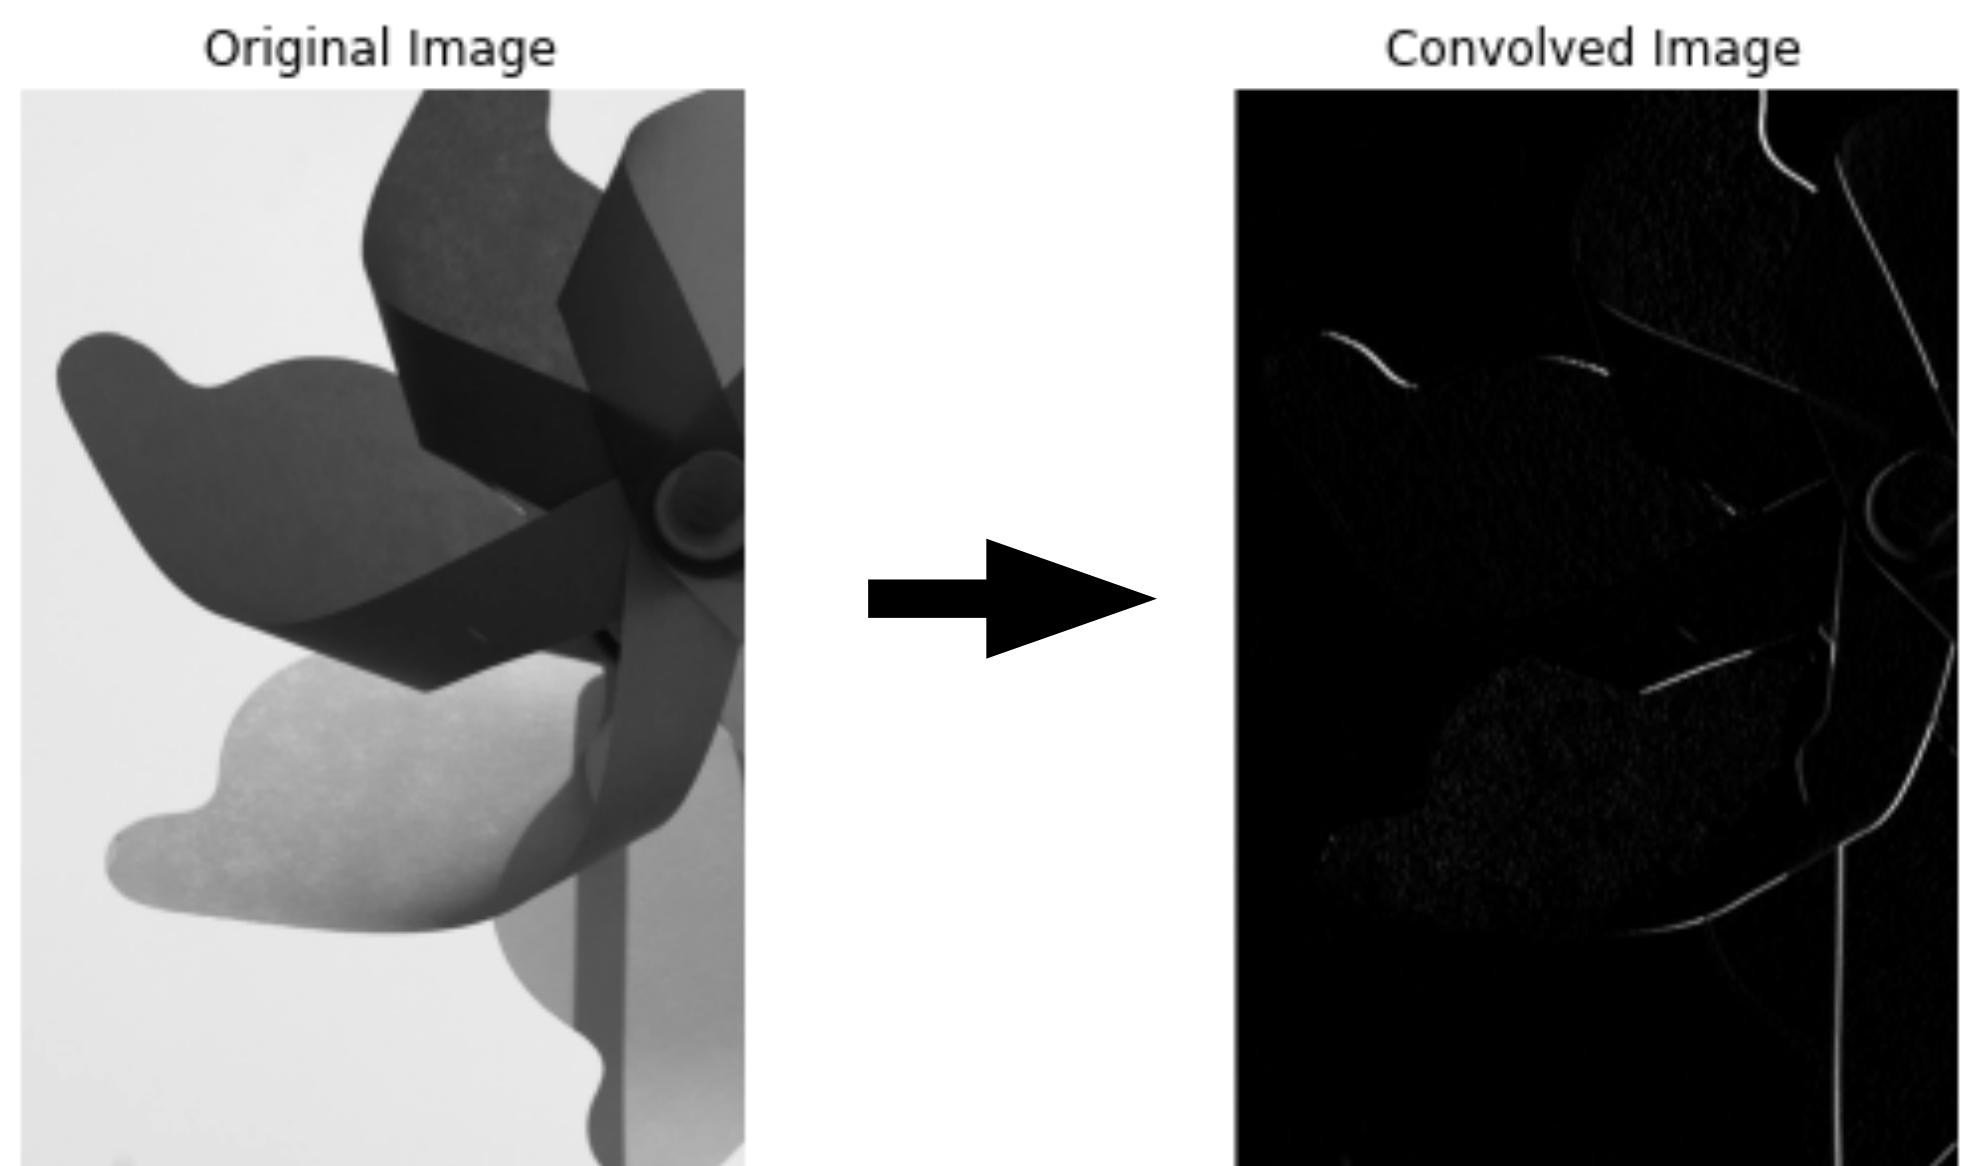


Temel Görüntü İşleme Teknikleri

Konvolüsyon (Convolution)

Konvolüsyon, görüntü işlemede temel bir işlemidir çünkü bir görüntüye filtreler yani çekirdekler (kernel) uygulayarak onu faydalı şekillerde dönüştürmemize ve özellikleri çıkarmamıza olanak tanır.

- Kenar Tespiti (Edge Detection)
- Bulanıklaştırma ve Yumuşatma (Blurring and Smoothing)
- Keskinleştirme (Sharpening)
- Gürültüyü Azaltma (Reducing Noise)
- Kontrastı İyileştirme (Improving Contrast)
- Özellik Çıkarma (Feature Extraction)



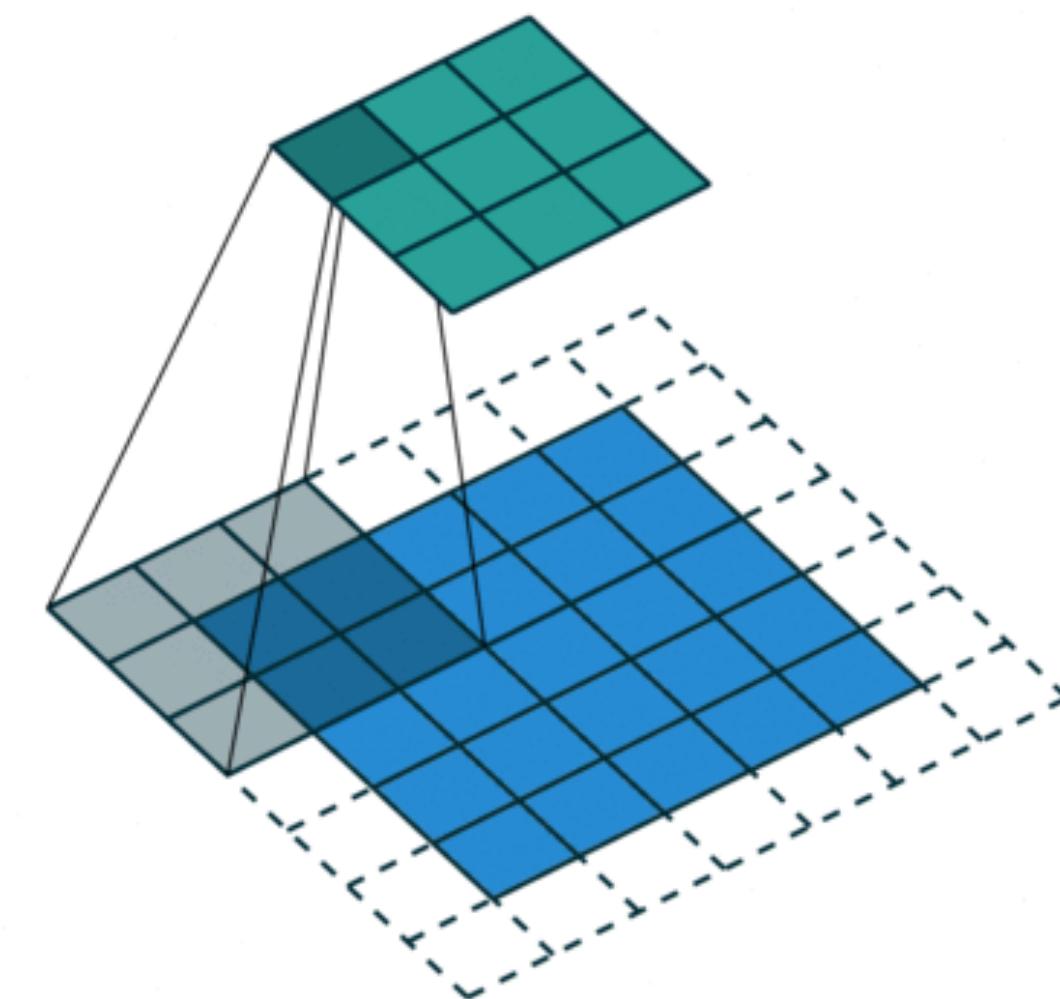
Kenar tespiti

Temel Görüntü İşleme Teknikleri

Konvolüsyon (Convolution)

Konvolüsyon Nasıl Çalışır?

- Bir çekirdek (örneğin, 3x3 matris), görüntü üzerinde piksel piksel "kaydırılır."
- Her konumda, çekirdekteki değerler görüntüdeki ilgili piksel değerleriyle çarpılır.
- Bu çarpımların toplamı, merkezi piksel değerinin yerine geçer.
- Bu işlem, görüntüdeki tüm pikseller için tekrarlanır.



Konvolüsyonel Sinir Ağları (CNNs)

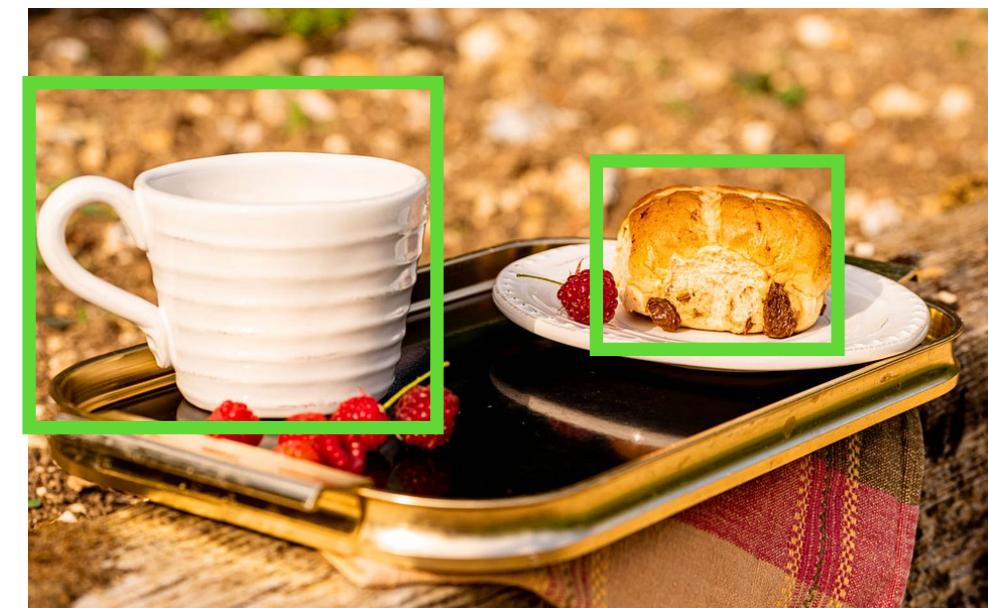
CNNs Nedir ve Nerede Kullanılır ?

Temel olarak görüntü işleme görevlerinde kullanılan ancak video, ses ve hatta metin gibi diğer veri türlerine de uygulanabilen bir derin öğrenme modelidir.

CNN'ler, verilerden özellikleri otomatik olarak öğrenir ve karmaşık desenleri tanıyalabilir.

- Görüntü Sınıflandırma
- Nesne Tespiti
- Yüz Tanıma
- Tıbbi Görüntü Analizi
- Video Analizi
- Otonom Araçlar
- Doğal Dil İşleme

Kahve kupası



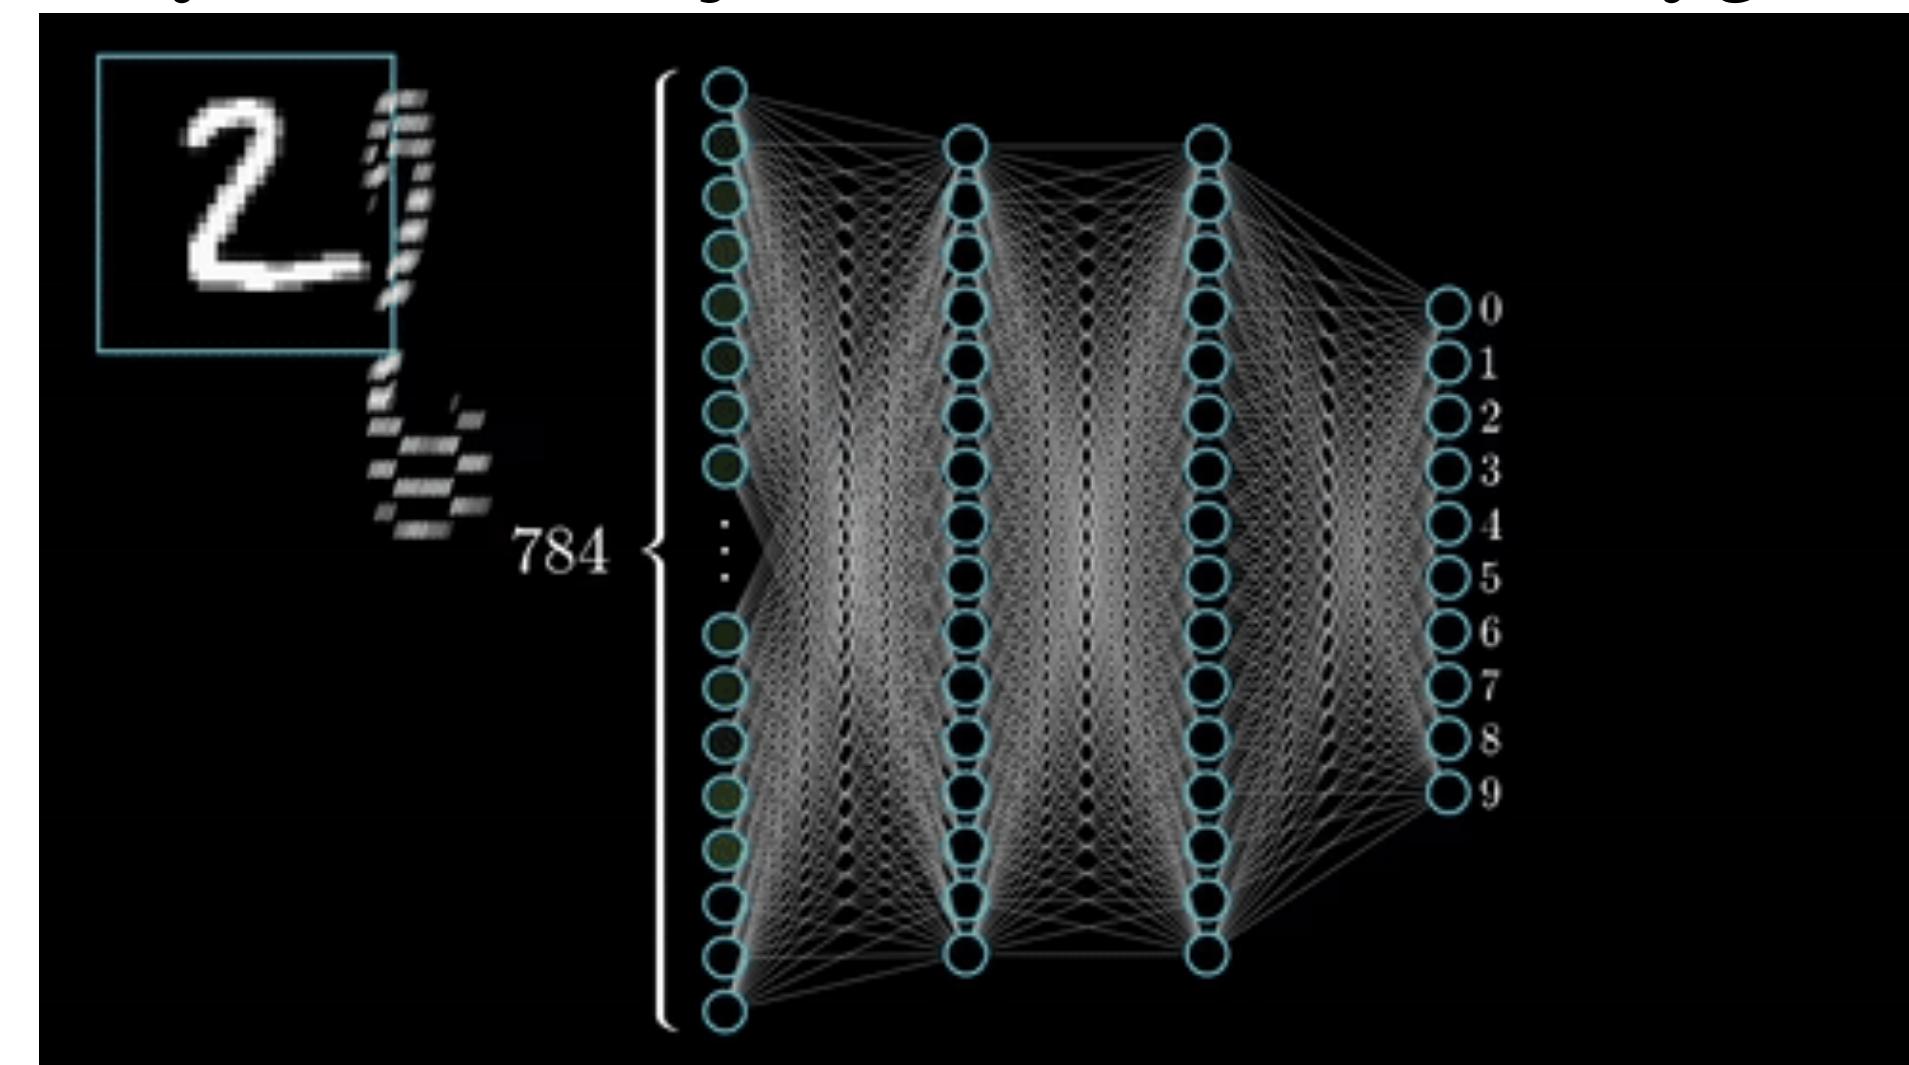
Konvolüsyonel Sinir Ağları (CNNs)

Temel Çalışma Prensibi

Konvolüsyon işleminin arkasındaki fikir, filtreler (çekirdekler) uygulayarak görüntüdeki kenarlar, dokular ve şekiller gibi desenleri tespit etmektir.

Bir filtre, genellikle 3×3 , 5×5 veya 7×7 boyutlarında küçük bir matristir. Filtre, görüntü üzerinde kaydırılarak konvolüsyon işlemi yapar ve özellik haritasını üretir.

Görüntünün çeşitli özelliklerini yakalamak için birden fazla filtre uygulanır.



Konvolüsyonel Sinir Ağları (CNNs)

Eğitilebilir Parametreler

Ağırlıklar (weights), her bir girdinin ağıın çıktısı üzerindeki etkisini kontrol eden çarpanlar gibidir.

Bir yapay sinir ağında, nöronlar arasındaki her bağlantının bir ağırlığı vardır. Daha büyük bir ağırlık, o ağırlığa bağlı olan girdinin çıktıyı daha fazla etkilemesi anlamına gelir.

Bias ağıın çıktıyı girdiden bağımsız olarak ayarlamasına olanak tanıyan kaydırmalar gibidir.

Konvolüsyonel Sinir Ağları (CNNs)

Model Nasıl Öğrenir?

İleri Yönlü Geçiş (Forward Pass):

Ağ, bir görüntü alır ve her nöron, ağırlıklar, bias ve bir aktivasyon fonksiyonu kullanarak çıktısını hesaplar. Ağ çıktısı, gerçek çıktı (doğru etiket, mesela "kedi" veya "köpek") ile karşılaştırılır.

Kayıp Fonksiyonu (Loss Function):

Tahmin edilen çıktı ile doğru etiket (ground truth) arasındaki fark, bir kayıp fonksiyonu ile ölçülür. Bu, ağıın tahminlerinin ne kadar yanlış olduğunu gösterir.

Konvolüsyonel Sinir Ağları (CNNs)

Model Nasıl Öğrenir?

Geri Yayılım (Backpropagation):

Ağ, ağırlıkları ve önyargıları ayarlamak için geri yayılım kullanır. Her ağırlık ve bias'ın hataya (veya kayba) ne kadar katkı sağladığını hesaplar.

Sonra, kaybı zamanla azaltan bir yöntem olan bir metot (örneğin gradient descent) kullanarak ağırlıklar ve bias'ı ayarlar.

Öğrenme (Learning):

Ağırlıklar ve bias'lar, ağıın tahminler yaptığı, bunları gerçek çıktı ile karşılaştırıldığı ve parametreleri hatayı azaltacak şekilde ayarladığı yinelemeler (iteration) veya dönemler (epochs) boyunca güncellenir

Konvolüsyonel Sinir Ağları (CNNs)

Model Nasıl Öğrenir?

Özetlemek gerekirse:

Ağırlıklar: Her bir girdinin etkisini kontrol eder.

Bias: Çıktıyı daha iyi uyum sağlamaası için kaydırır.

Öğrenme: Ağ, tahmin hatasını azaltmak için ağırlıkları ve önyargıları ayarlayarak öğrenir.

Amaç, ağırlıklar ve bias'ları güncelleşerek tahmin edilen ve doğru etiket arasındaki hatayı kademeli olarak minimize etmek ve ağın daha iyi tahminler yapmasını sağlamaktır.

Konvolüsyonel Sinir Ağları (CNNs)

Temel Katmanlar

Girdi Katmanı (Input Layer):

Görüntünün ağın içine verildiği yerdir.

Konvolusyon Katmanı (Convolutional Layer):

Kenarlar, dokular ve şekiller gibi özellikleri tespit etmek için filtreler (çekirdekler) uygular.

Görüntüdeki önemli desenleri vurgulayan özellik haritaları (feature maps) üretir.

Konvolüsyonel Sinir Ağları (CNNs)

Temel Katmanlar

Aktivasyon Katmanı:

Özellik haritalarına, ReLU gibi doğrusal olmayan bir aktivasyon fonksiyonu uygular, bu da doğrusal olmayanlık ekler.

Ağa, sadece doğrusal ilişkilerle modellenemeyen karmaşık desenleri öğrenmesinde yardımcı olur.

Havuzlama Katmanı (Pooling):

Özellik haritalarının boyutunu, yalnızca en önemli bilgiyi tutarak, alt örnekleme (downsampling) yaparak küçültür.

Hesaplamayı azaltmaya yardımcı olur, modeli daha verimli hale getirir ve görüntüdeki küçük değişikliklere (örneğin, kaymalar veya bozulmalar) karşı bir dereceye kadar değişmezlik sağlar.

Konvolüsyonel Sinir Ağları (CNNs)

Temel Katmanlar

Tam Bağlantılı Katman (Dense Layer):

Konvolüsyon ve havuzlama yoluyla çıkarılan özelliklerini birleştirir.

Her nöron, önceki katmandaki her nörona bağlıdır. Öğrenilen özelliklere dayanarak tahminler veya sınıflandırmalar yapmaya yardımcı olur.

Çıktı Katmanı (Output Layer):

Ağın nihai çıktısını üretir, örneğin bir sınıf etiketi veya bir olasılık.

Konvolüsyonel Sinir Ağları (CNNs)

Temel Katmanlar

Özetlemek gerekirse:

Girdi Katmanı: Veriyi alır.

Konvolüsyon Katmanı: Özellikleri çıkarır.

Aktivasyon Katmanı: Doğrusal olmayanlık ekler.

Havuzlama Katmanı: Özellik haritalarının boyutunu küçültür.

Tam Bağlantılı Katman: Nihai karar için özellikleri birleştirir.

Çıktı Katmanı: Nihai tahmini üretir.

Konvolüsyonel Sinir Ağları (CNNs)

Hiperparametreler

Filtre Boyutu: Konvolüsyonda kullanılan kaydırma penceresinin boyutu (örneğin, 3x3, 5x5).

Filtre Sayısı: Bir konvolüsyon katmanında uygulanan çekirdeklerin sayısı.

Adım (Stride): Filtrenin konvolüsyon sırasında hareket ettiği piksel sayısı.

Dolgu (Padding): Çıktı boyutunu kontrol etmek için girdinin etrafına ekstra pikseller (örneğin sıfırlar) eklemek.

Aktivasyon Fonksiyonu: Konvolüsyondan sonra doğrusal olmayanlık ekleyen fonksiyon (örneğin, ReLU, Sigmoid).

Konvolüsyonel Sinir Ağları (CNNs)

Hiperparametreler

Havuzlama Boyutu: Havuzlama işlemleri için pencere boyutu (örneğin, Maks Havuzlama için 2x2).

Öğrenme Oranı (Learning Rate): Ağırlıkların ve bias'ların eğitim sırasında ne kadar güncelleneceğini kontrol eder.

Yığın Boyutu (Batch Size): Tek bir ileri/geri geçişte işlenen eğitim örneklerinin sayısı.

Dönem Sayısı (Number of Epochs): Tüm veri kümelerinin ağdan geçirilme sayısı (eğitim sırasında).

Optimizasyon Yöntemi (Optimizer): Ağırlıkları ve önyargıları güncelleyen algoritma (örneğin, SGD, Adam).

Kayıp Fonksiyonu (Loss Function): Tahminlerin gerçek değerlerden ne kadar uzak olduğunu ölçen fonksiyon (örneğin, Çapraz Entropi).



Konvolüsyonel Sinir Ağları (CNNs)

Veri Çoğaltma (Data Augmentation)

Mevcut görüntülere dönüşümler uygulayarak bir veri kümесinin boyutunu yapay olarak artırma işlemidir. Bu dönüşümler; döndürme, gürültü ekleme, kırpma, parlaklığını değiştirme gibi işlemleri içerir.

Aşırı Öğrenmeyi (Overfitting) Azaltır:

Aşırı öğrenme, bir CNN'in eğitim verilerinde iyi performans gösterip, görülmemiş verilerde kötü performans göstermesi durumudur. Veri çoğaltma, veri setinde çeşitlilik yaratarak modelin daha iyi genelleme yapmasını sağlar.

Model Performansını İyileştirir:

Modele verinin hafifçe değiştirilmiş versiyonlarını göstererek, modelin daha dayanıklı ve daha doğru öğrenmesini sağlar.

Küçük Veri Setlerini Telafi Eder:

Büyük veri setlerinin toplanmasının zor olduğu durumlarda, veri çoğaltma daha fazla eğitim örneği oluşturur.

Değişmezliği Geliştirir:

Ağ, döndürme, ölçek, aydınlatma veya gürültü gibi gerçek dünyada yaygın olan değişimlere karşı değişmez hale gelir.

Konvolüsyonel Sinir Ağları (CNNs)

Örnek Yapı

```
input_shape = (64, 64, 3) # Image size (height, width, channels)
num_classes = 10 # For classification 10 classes
conv_filters = 32 # Number of filters for convolution layers
kernel_size = (3, 3) # Size of the convolution kernel
pool_size = (2, 2) # Size of the pooling layer
dense_units = 128 # Number of units in the fully connected layer
learning_rate = 0.001 # Learning rate for the optimizer

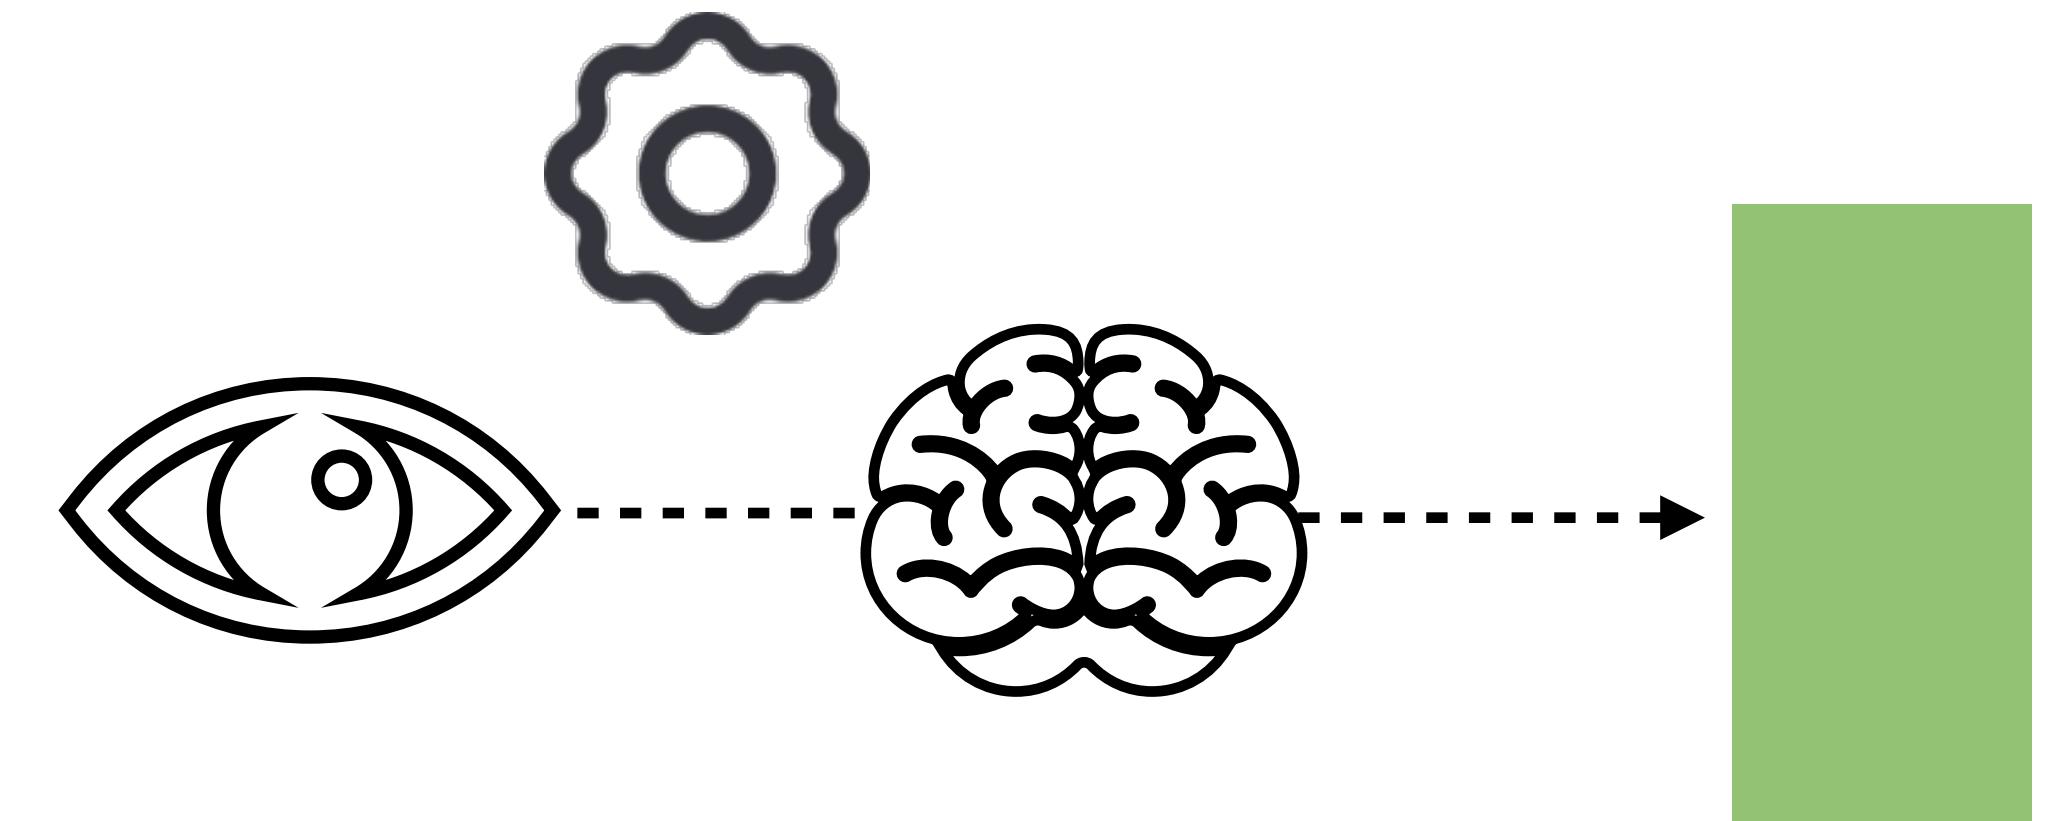
model = models.Sequential()
model.add(layers.InputLayer(input_shape=input_shape))
model.add(layers.Conv2D(filters=conv_filters, kernel_size=kernel_size, activation='relu'))
model.add(layers.MaxPooling2D(pool_size=pool_size))
model.add(layers.Conv2D(filters=conv_filters*2, kernel_size=kernel_size, activation='relu'))
model.add(layers.MaxPooling2D(pool_size=pool_size))
model.add(layers.Flatten())
model.add(layers.Dense(dense_units, activation='relu'))
model.add(layers.Dense(num_classes, activation='softmax'))

model.compile(optimizer=Adam(learning_rate=learning_rate),
              loss='sparse_categorical_crossentropy', # for multi-class classification
              metrics=['accuracy'])
```

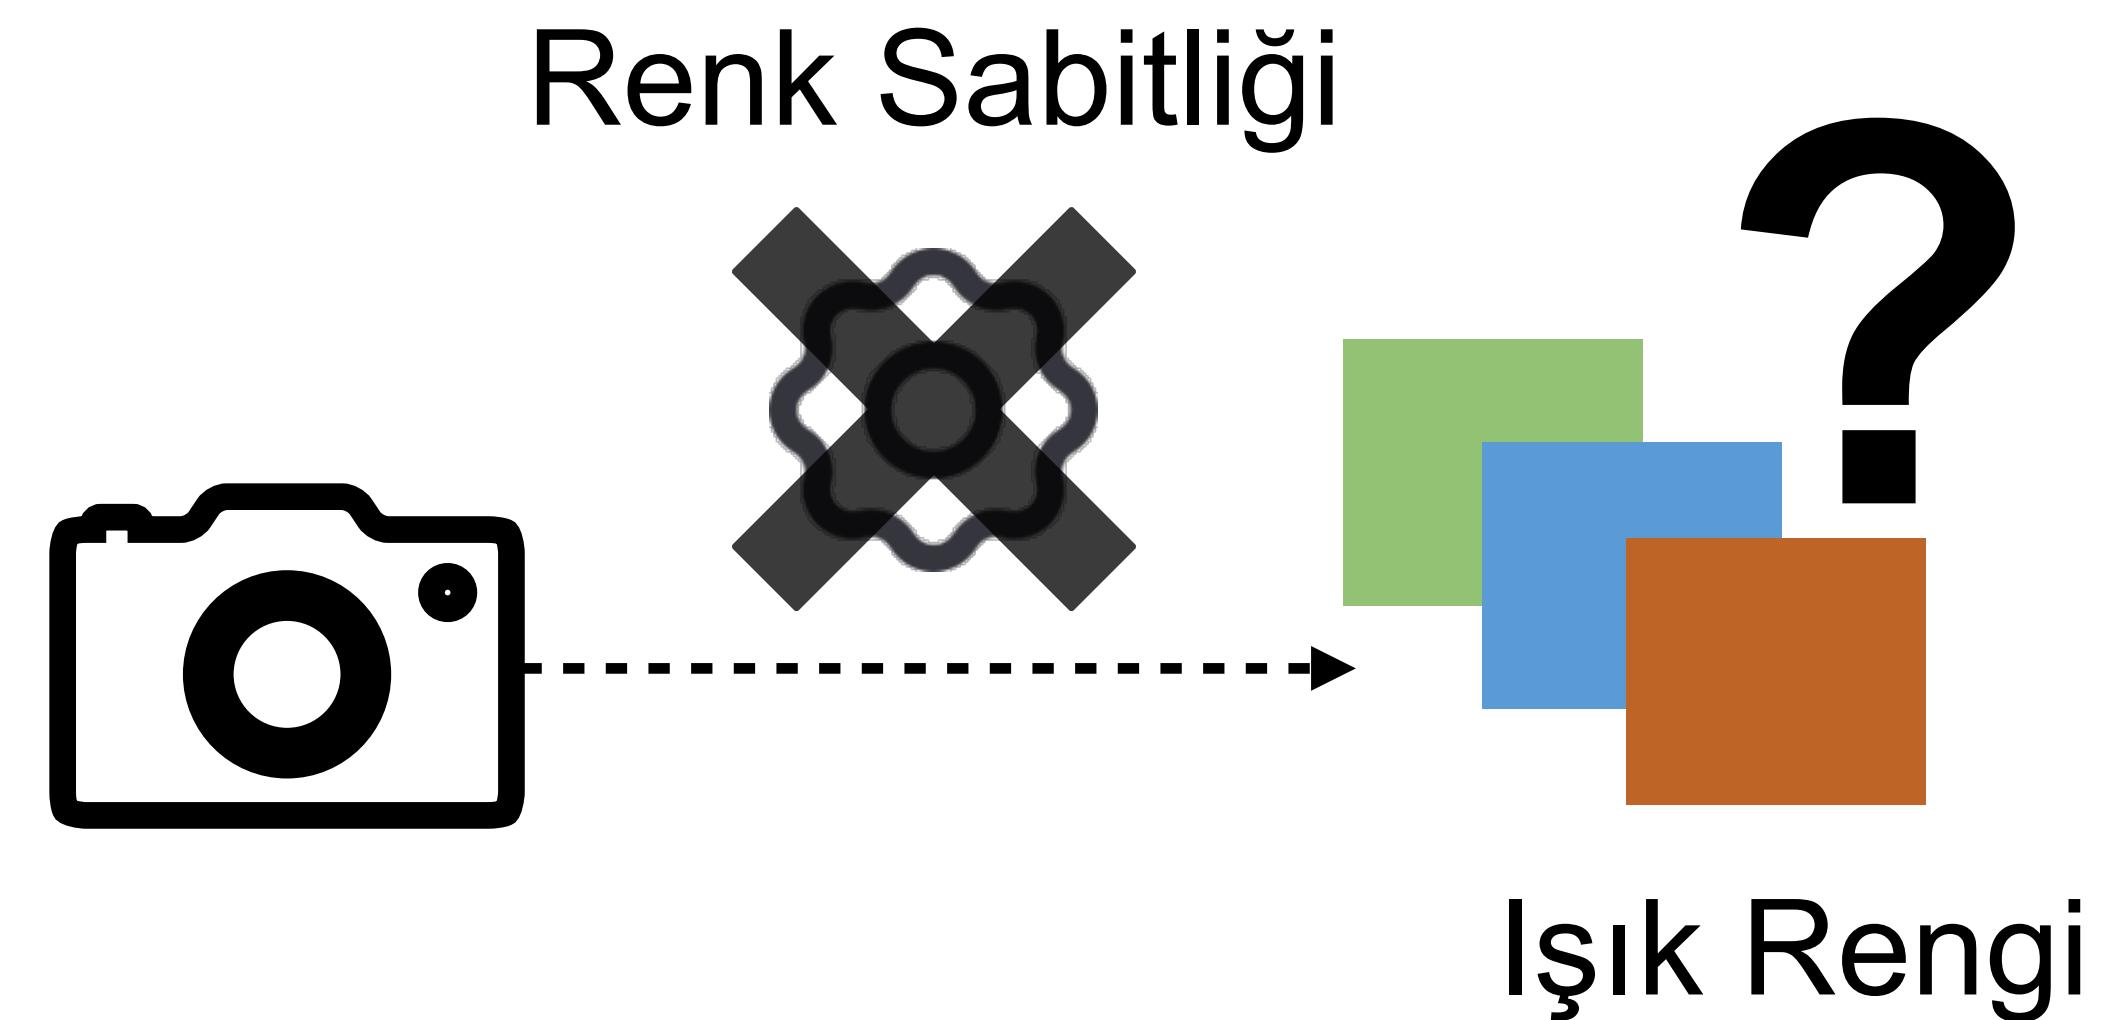
Renk Sabitliği



Renk Sabitliği



Renk Sabitliği



Renk Sabitliği

$$I = R \circ L$$

Girdi Resmi



Renk Sabitliği

$$I = R \circ L$$

Girdi Resmi



$$L$$

Tahminler



$$R \approx I/L$$

Düzeltilmiş Resim

